Exame Final

Disciplina: CCO50 - Digital Speech Processing
Professor: Dr Eng Rodrigo Capobianco Guido
Aluno: Levi Rodrigues da Silva **PGE**: 240214

---

(1): Design an FIR filter (q[n]), subtype I, of order M = 8 to cut-off frequencies within the range 2000 Hz ⇠ 4000 Hz, allowing for all the others to pass through. Assume that the input signal to be filtered (x[n]) was sampled at 22050 samples per second. Normalize the filters' coefficients in such a way that the filter presents a gain of 0dB in the pass-band. Lastly, write down the difference equation to filter an input signal x[n] by using q[n].

Tradução: Projete um filtro FIR (q[n]), subtipo I, de ordem M = 8 para cortar frequências dentro da faixa de 2000 Hz ⇠ 4000 Hz, permitindo a passagem de todas as outras. Suponha que o sinal de entrada a ser filtrado (x[n]) foi amostrado a 22050 amostras por segundo. Normalize os coeficientes dos filtros de forma que o filtro apresente um ganho de 0 dB na banda de passagem. Por fim, escreva a equação diferencial para filtrar um sinal de entrada x[n] usando q[n].

Solução:

Dados:

Projetar q[n].
Filtro digital FIR Subtipo I
Ordem **M=8** portanto 9 coeficientes (**q0, q1 ,q2, q3, q4, q5, q6, q7 e q8**)
Filtro Rejeita-faixa: (**2000 a 4000**) hz
X[n] foi amostrado **22050 amostras/s**

a) Encontrar q[n]
b) Normalizar os coeficientes do filtro (o db)
c) Escreva uma equação diferencial

Passo 1: Normalizar as frequências inferior e superior do filtro para a velocidade angular.

$$\boxed{Wc=2\pi\, fc / fa}$$

Inferior: $Wci = 2\pi \cdot (2000/22050) = 4000\pi/22050 = 80\,\pi/\,441$

A velocidade angular inferior é : $\mathbf{Wcl = 80\,\pi/\,441}$

Superior: $Wcs = 2\pi.\ 4000/22050 = 160\,\pi/\,441$

A velocidade angular superior é : **Wcs = 160 π/ 441**

Passo 2: Projeto do filtro digital FIR subtipo I e M=8.
Usando as fórmulas:

$$q[n] = \frac{\sin(\pi(n-M/2))}{\pi\,(n-M/2)} - p[n]$$

O primeiro termo representa o filtro passa tudo ideal da função sinc (δ[n]).
O segundo termo é o p[n] que é a **combinação do segundo e terceiro termos (uma diferença de dois passa-baixas)** que resulta no passa-faixa.

$$h[n] = \frac{\sin(wc(n-M/2)}{\pi\,(n-M/2)}$$

Depois utilizando a soma do passa tudo pelo passa faixa, obteremos o rejeita faixa.

$$q[n] = \delta[n] - p[n]$$

Colocando estas fórmulas no gráfico, para entender melhor, temos:

Figura 1 - Filtro Rejeita Faixa a partir de filtro Passa Baixa

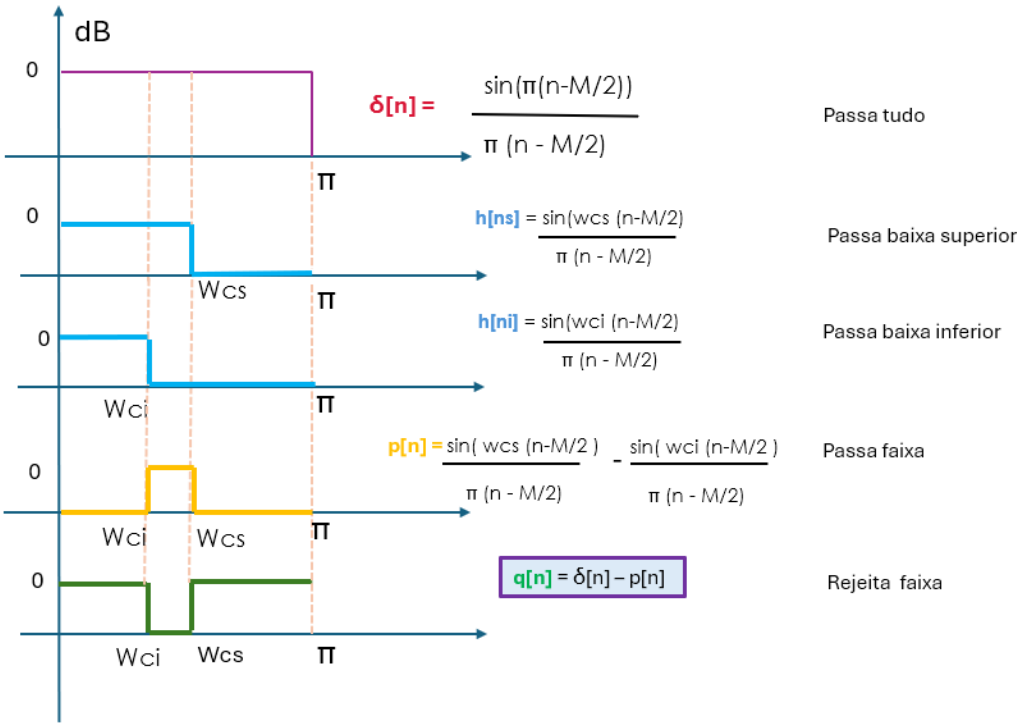

n – M/2 = n -8/2 = **n - 4**

Usando a frequência angular calculada e o deslocamento, temos:

$$q[n] = \frac{\sin(\pi(n-4))}{\pi\,(n-4)} - \left[\frac{\sin((160\,\pi/441).\,(n-4))}{\pi\,(n-4)} - \frac{\sin(((80\,\pi/441)\,.\,(n-4))}{\pi\,(n-4)}\right]$$

Temos a distribuição do sinal de menos e, portanto, :

$$q[n] = \frac{\sin(\pi(n-4))}{\pi\,(n-4)} - \frac{\sin((160\,\pi/441).\,(n-4))}{\pi\,(n-4)} + \frac{\sin(((80\,\pi/441)\,.\,(n-4))}{\pi\,(n-4)}$$

OBS.: Se n=4 ou q[4], teremos um denominador igual a zero e teremos que usar o conceito de limite.

q[n]= 1 – (160/441)(1)+(80 /441)(1)= 441-160 + 80/441 = 361/441 = -0,8186

Portanto os valores de n=0 até n=8 são:

n	q[n]
0	-0,1371
1	-0.1351
2	-0,0236
3	0,1170
4	0,8186
5	0,1170
6	-0,0236
7	-0,1351
8	-0,1371

a) **Encontrar q[n]**

q[n]=[−0.1371, −0.1351 ,−0.0236,0. 1170,0. 8186,0. 1170, −0.0236, −0.1351, −0.1371]

b) Normalizar os coeficientes do filtro (o db)

A soma dos coeficientes de **q[n] = 0,4610**
Para normalizar o qn] e ter ganho unitário ou 0 dB, somente dividir cada coeficiente pela soma q[n]. Portanto q[n] normalizado:

qnorm[n]=[−0.2974,−0.2931,−0.0512,0.2538,1.7757,0.2538,−0.0512,−0.2931,−0.2974]

c) Escreva uma equação diferencial.

y[n]= −0.2974x[n]−0.2931x[n−1]−0.0512x[n−2]+0.2538x[n−3]+1.7757x[n−4]+0.2538 x[n−5]−0.0512x[n−6]−0.2931x[n−7]−0.2974x[n−8]

Esta equação diferencial pode ser vista no infográfico abaixo:

Figura 2 - Infográfico de um filtro Rejeita Faixa

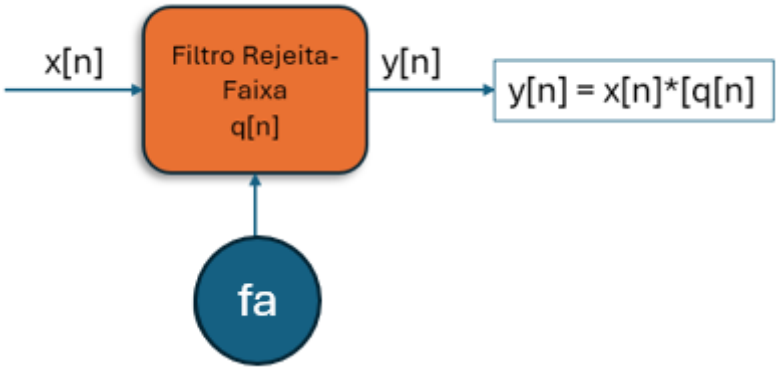

A fórmula representa a resposta impulsiva de um filtro **rejeita-faixa** (ou filtro **notch**, também chamado de ***band-stop filter***) construído a partir da diferença entre dois filtros passa-baixa.

(2): Design an FIR filter with the following specifications:

0.98 <= | H(e^{jw}) | <= 1.02, in the range 0 <= w <= 0.1 π
H(e^{jw}) | <= 0.06, in the range 0.4π <= w <= π

Then, normalize the windowed filter, write down the difference equation to implement the filter you have just designed in a computerbased application, and depict the corresponding block diagram.

Tradução: Projete um filtro FIR com as seguintes especificações:
0.98 <= | H(e^{jw}) | <= 1.02, in the range 0 <= w <= 0.1π
H(e^{jw}) | <= 0.06, in the range 0.4π <= w <= π

Em seguida, normalize o filtro em janela, anote a equação diferencial para implementar o filtro que você acabou de projetar em um aplicativo computadorizado e descreva o diagrama de blocos correspondente.

Solução:

Banda de passagem de **(H(e^{jw})**: 0.98 a 1.02 Δ (delta) =0.02

são os valores em módulo possíveis da **amplitude** no intervalo de 0 <= w <= 1.02π. No caso do intervalo w>= 0.4π até w=π a amplitude é quase zero (0.06).

Portanto **h[n] = filtro passa baixa,** pois no intervalo de uma janela π, w tem valores próximos de 1 no início e próximos de zero no final.

Como se trata de um filtro **FIR**, podemos usar a tabela de janela (Windows) que servem para **suavizar** a resposta impulsional ideal de um filtro, controlar os lóbulos laterais na resposta em frequência e definir a transição entre banda passante e banda rejeitada.

window	equation	order	att.
rectangular	$w[n] = 1, (0 \leqslant n \leqslant M)$	$M = \frac{0.9}{\Delta_t}$	-21dB
Barlett	$w[n] = \begin{cases} \frac{2n}{M}, (0 \leqslant n \leqslant \frac{M}{2}) \\ 2 - \frac{2n}{M}, (\frac{M}{2} + 1 \leqslant n \leqslant M) \end{cases}$	$M = \frac{3.0}{\Delta_t}$	-25dB
Hanning	$w[n] = \frac{1}{2} - \frac{1}{2}\cos(2\pi\frac{n}{M})$	$M = \frac{3.1}{\Delta_t}$	-44dB
Hamming	$w[n] = 0.54 - 0.46 \cdot \cos(2\pi\frac{n}{M})$	$M = \frac{3.3}{\Delta_t}$	-53dB
Blackman	$w[n] = 0.42 - 0.5 \cdot \cos(2\pi\frac{n}{M}) + 0.08 \cdot \cos(4\pi\frac{n}{M})$	$M = \frac{5.5}{\Delta_t}$	-74dB

(*): att. = band attenuation; Δ_t = transition band in Hertz.

Para definir qual o tipo de janela a ser usado, devo pegar o valor mais restritivo da amplitude entre os valores próximo do ganho máximo, que no nosso caso **Δ =0.02** e a amplitude mínima **0.06** .
A amplitude mais restritiva é **0.02**.

Portanto - 20 log 0.02 = -33,9794 = **-34 dB**.

Olhando a tabela de janela que seja maior que -34dB, temos a janela de **Hanning**.

Podemos definir graficamente que:

Figura 3 - Função de Transferência

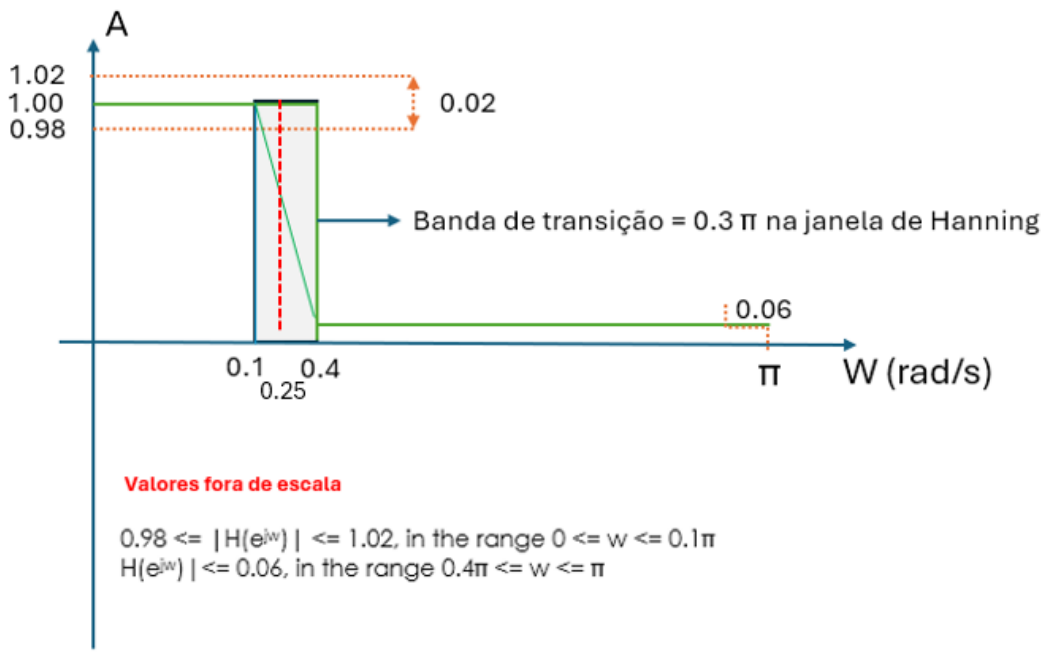

Após definido a janela, temos o número de ordem dos coeficientes definido por:

M = 3.1 / Δt

Como não temos Δt temos que calcular.

Δw = 0.4 - 0.1 **Δw = 0.3 rad/s**

W = 2πf => 2π Δf
Δf = 0.3π/ 2π = 0.15 hz

Δf = 0.15 hz

Calculando número de ordem:

M = 3.1 / 0.15) = 20.666

M = 21

Portanto teremos 22 coeficientes de q[n].

Usando o filtro de passa baixa temos a fórmula:

$$\mathbf{h[n]} = \frac{\sin(wc(n-M/2)}{\pi\,(n - M/2)}$$

Usando os nossos dados na transição temos que o corte **do passa-baixa ideal**. Para um passa-baixa com banda de transição entre 0.1π e 0.4π, a frequência de corte ideal é Wc = (0.1π + 0.4π) / 2 = 0.25π.

$$h[n]= \frac{\sin(0.25\,\pi\,(n-(21/2))}{\pi(n - (21/2)} = h[n]= \frac{\sin(0.25\,\pi\,(n-10.5)}{\pi(n - 10.5)}$$

w[n]=0.5−0.5cos(2πn)

A fórmula da janela de Hanning **W[n] = 0.5 – 0.5 cos(2π.n/M)**

Devido a transição do valor alto para o valor baixo do filtro passa baixa, agora usando a janela de Hanning, temos:

$$\mathbf{h[n] = 0.5 - 0.5\cos(2\pi.n\text{-}M/2) \quad x \quad \frac{\sin(wc(n\text{-}M/2))}{\pi(n - M/2)}}$$

Onde o primeiro termo é a janela de Hanning ou poderia ser outra da tabela e o segundo termo é o filtro passa baixa impulsional ideal.

Desta forma o h[n] deste exercício com M=21 e Wc_ideal = 0.25π:

$$h[n]= 0.5 - 0.5\cos(2\pi.n/21)) \times \frac{\sin(0.25(n-10.5)}{\pi\,(n-10.5)}$$

Os cálculos ficam:

Coeficientes Não Normalizados:

h[0] = 0.0000000
h[1] = -0.0000572
h[2] = -0.0004706
h[3] = -0.0015561
h[4] = -0.0033880
h[5] = -0.0057715
h[6] = -0.0076892
h[7] = -0.0071911
h[8] = 0.0129759
h[9] = 0.0497500
h[10] = 0.0979316
h[11] = 0.1161386
h[12] = 0.0832876
h[13] = 0.0747444

h[14] = 0.0647180
h[15] = 0.0400084
h[16] = 0.0195038
h[17] = -0.0179753
h[18] = -0.0310636
h[19] = -0.0292558
h[20] = -0.0150099
h[21] = 0.0000000

Soma dos coeficientes não normalizados: **0.3805404**

Portanto h[n] normalizado :

hnorm[n]= h[n] / Soma

Portanto hnorm[n]:

n	h[n] (não norm.)	h_norm[n] = h[n] / 0.3805404
0	0,0000000	0,0000000
1	-0,0000572	-0,0001503
2	-0,0004706	-0,0012367
3	-0,0015561	-0,0040909
4	-0,0033880	-0,0089037
5	-0,0057715	-0,0151666
6	-0,0076892	-0,0202061
7	-0,0071911	-0,0189000
8	0,0129759	0,0341005
9	0,0497500	0,1307335
10	0,0979316	0,2573504
11	0,1161386	0,3051934
12	0,0832876	0,2188667
13	0,0747444	0,1964177
14	0,0647180	0,1700688
15	0,0400084	0,1051351
16	0,0195038	0,0512528
17	-0,0179753	-0,0472396
18	-0,0310636	-0,0816362
19	-0,0292558	-0,076882
20	-0,0150099	-0,0394443
21	0,0000000	0,0000000

A equação diferencial (ou equação da diferença) de um filtro FIR descreve como a saída y[n] é calculada a partir da entrada x[n] e dos coeficientes do filtro.

$$y[n] = \sum_{k=0}^{M} h_{norm}[k]x[n-k]$$

y[n]norm=0.0000000)·x[n] - 0,0001503·x[n−1] - 0,0012367·x[n−2] -0,0040909 x[n−3] -0,0089037x[n−4] -0,0151666x[n−5] -0,0202061·x[n−6] -0,0189000030x[n−7] +0,0341005x[n−8] + 0,1307335x[n−9] + 0,2573504x[n−10] + 0,3051934x[n−11] 0,2188667x[n−12] + 0,1964177x[n−13] + 0,1700688x[n−14] + 0,1051351x[n−15] + 0,0512528x[n−16] -0,0472396x[n−17] -0,0816362·x[n−18] -0,076882.x[n−19] - 0,0394443.x[n−20]+ 0.0000000)·x[n-21]

Figura 4 - Infográfico da equação diferencial

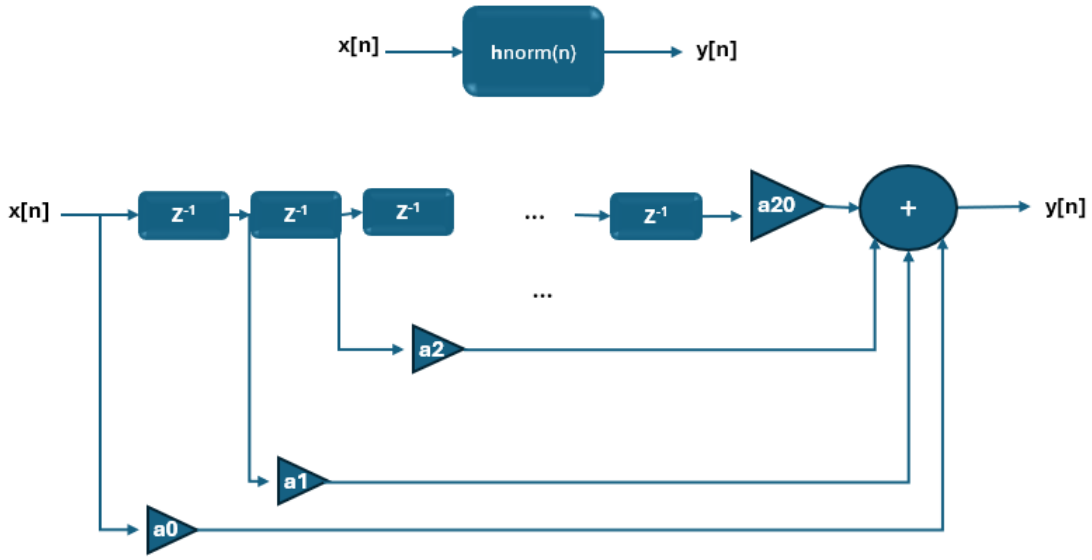

A equação diferencial pode ser descrita no infográfico resumido como um x[n] que é o sinal de entrada, passando por um filtro FIR digital normalizado e apresentando o resultado na saída y[n].
Através de comparar a saída com a entrada, ou seja, FT= Y[W] / X[W] na frequência, temos a Função de Transferência, também conhecida como Curva de Bode ou Ganho, representado na figura 3.
Detalhando os coeficientes da equação diferencial, o infográfico mostra que o sinal de entrada tem um ganho em a0 e até a20, valores em cascata, conforme nossa equação diferencial calculada. Na frequência estes valores ou ganhos são multiplicados.
Para número de ordem M=20 ou 21 coeficientes, temos:

- **Entrada x[n]:** Representa o sinal que está sendo alimentado no filtro em cada instante de tempo n.
- **Blocos Z^{-1}:** Cada um desses blocos representa um atraso de uma amostra no tempo. Como o filtro tem ordem M=20, terá uma cadeia de 20 blocos

Z^{-1} em sequência. A figura mostra essa sequência (com "...") até Z^{-1} para o coeficiente a20.

- **"Taps" (derivações):** De cada ponto na linha de atraso (incluindo a entrada direta x[n] e após cada Z^{-1}), um sinal é "derivado".
- **Multiplicadores (a0, a1, a2, ..., a20):** Cada sinal derivado é multiplicado por um coeficiente específico do filtro.
  a) a0 multiplica x[n] (a entrada atual).
  b) a1 multiplica x[n-1] (a entrada atrasada por 1 amostra).
  c) a2 multiplica x[n-2] (a entrada atrasada por 2 amostras).
  d) ...
  e) a20 multiplica x[n-20] (a entrada atrasada por 20 amostras). *Esses "aK" na figura correspondem aos nossos coeficientes normalizados hnorm[k] que calculamos (por exemplo, a0 é hnorm[0], a1 é hnorm[1], e assim por diante até a20 que é hnorm[20])*.
- **Somador (+ ou Σ):** Todas as saídas dos multiplicadores são somadas em um único ponto para produzir o sinal de saída y[n].

(3) Explain, in a short paragraph, the concept of window. What is it used for? Why is it important?

Tradução: Explique, em um breve parágrafo, o conceito de janela. Para que serve?
Por que é importante?

Solução:

Em Processamento Digital de Sinais, o conceito de "janela" refere-se a uma função de tempo finita utilizada para multiplicar a resposta ao impulso ideal, que é infinita em duração, de um filtro FIR digital.
Esta janela pode ter valor ideal de **1** (100%) ou considerar no real os sinais de espúrios, chegando próximo dos valores reais.
Sua principal finalidade é transformar uma resposta ao impulso ideal (e.g., uma função sinc para um filtro passa-baixas), que teoricamente se estende ao infinito, em uma resposta de duração finita, o que a torna implementável em sistemas digitais.
A importância da janela reside em sua capacidade de mitigar o efeito **Gibbs**, que são oscilações indesejadas na resposta em frequência do filtro causadas pelo truncamento abrupto da resposta ao impulso ideal, melhorando assim o desempenho do filtro em termos de atenuação na banda de transição e na banda de rejeição.

(4): Find the transfer function H[z] whose poles are at z = −1/4
And , z = 1/3, in addition to one zero at z = 1/5 . Write down the corresponding difference equation. Is the transfer function stable and causal?

Tradução: Encontre a função de transferência H[z] cujos polos estão em z = −1/4 E , z = 1/3, além de um zero em z = 1/5. Escreva a equação diferencial correspondente. A função de transferência é estável e causal ?

Solução:

A função de transferência é dada pela fórmula:

$$H[Z] = \frac{Y[Z]}{X[Z]} = \frac{b0 + b1\, Z^{-1} + b2\, Z^{-2} + \ldots}{a0 + a1\, Z^{-1} + a2\, Z^{-2} + \ldots}$$

Na função discreta ela é dada como:

$$H[z] = K \frac{\prod_{i=1}^{M} (z - z_i)}{\prod_{j=1}^{N} (z - p_j)}$$

onde:

H[Z} é ganho ou função de transferência no domínio Z da frequência.
K é constante b0/a0
i = zeros, porque está no numerador
j = pólos, porque está no denominador
∏ símbolo pi maiúsculo da letra grega representando um **produtório**. É análago ao símbolo (∑) somatório, mas em vez de somar os termos, ele multiplica.
z_i Representa o i-nésimo zero da Função de Transferência. Os zeros são os valores de z que tornam o números igual a zero.
p_j Representa o i-nésimo polo da Funcçao de Transferência. Os polos são os valores de z que tornam o denominador igual a zero, onde teoricamente torna o ganho infinito, mas na prática serve para determinar a causalidade, estabilidade e forma da resposta transitória de um sistema.
M é o total de zeros e N o total de polos.

Por estas características ele se trona um **filtro IIR**.

Temos os dados:

p_j = -1/4 p_j= 1/3 Z_i = 1/5

Substituindo na fórmula temos:

$$H[z] = K \frac{(z - 1/5)}{(z + 1/4)(z - 1/3)}$$

x'

A expressão $(z+1/4)(z-1/3) = z^2 - 1/3z + 1/4z - (1/4 \times 1/3) = z^2 - (1/12)z - 1/12$

$$H[z] = K \frac{(z - 1/5)}{z^2 - (1/12)z - 1/12}$$

Para obter a **equação diferencial**, é útil expressar H[z] em termos de potências negativas de z. Para isso, dividimos o numerador e o denominador pela maior potência de z no denominador (z^2):

$$H[z] = K \frac{z/z^2 - (1/5)/z^2}{z^2/z^2 - (1/12)z/z^2 - (1/12)z^2} = K \frac{Z^{-1} - (1/5)Z^{-2}}{1 - (1/12)Z^{-1} - (1/12)Z^{-2}}$$

Como :

$H[Z] = \frac{Y[Z]}{X[Z]}$ então:

$$\frac{Y(z)}{X(z)} = \frac{z^{-1} - 1/5z^{-2}}{1 - \frac{1}{12}z^{-1} - \frac{1}{12}z^{-2}}$$

Multiplicando em cruz:

$$Y(z)\left(1 - \frac{1}{12}z^{-1} - \frac{1}{12}z^{-2}\right) = X(z)\left(z^{-1} - \frac{1}{5}z^{-2}\right)$$

$$Y(z) - \frac{1}{12}z^{-1}Y(z) - \frac{1}{12}z^{-2}Y(z) = z^{-1}X(z) - \frac{1}{5}z^{-2}X(z)$$

Aplicando a Transformada Z Inversa (onde z^{-n} F[z] corresponde a f[k−n] no domínio do tempo):

$y[n] - (1/12)y[n-1] - (1/12)y[n-2] = K\,x[n-1] - 1/5Kx[n-2]$ se considerarmos K=1

A equação diferencial fica:

$y[n] = (1/12)y[n-1] + (1/12)y[n-2] + x[n-1] - (1/5)x[n-2]$

Causalidade: Ela é causal se o grau do polimônio do numerador for menor ou igual ao grau do polimônio do denominador. No caso o numerador M=1 e no denominador N=2. Portanto este polimônio **é causal**;.

Estabilidade: todos os seus polos devem estar localizados dentro do círculo unitário, ou seja, ter magnitude menor que 1, |pj|<1 |. No nosso caso os módulos são 1/3 e 1/4 portanto este **sistema estavel**.

(5): Consider the hypothetical speech signal segment s[n] = {−1, 2, −3, 3, 2, 1, −1, −1, −4, 5, 5, 4}, sampled at 16000 samples per second. Assume that a sliding rectangular window w[n] traverses it in order to extract features for inclusion in the feature vector f[n], covering 0.125ms at each placement, with 50% overlap between consecutive windows. What is the length of f[n]? What are the values in f[n], considering the ordinary entropy, calculated with the log basis β = 10, as being the feature used?

Tradução: Considere o segmento hipotético de sinal de fala s[n] = {−1, 2, −3, 3, 2, 1, −1, −1, −4, 5, 5, 4}, amostrado a 16.000 amostras por segundo. Suponha que uma janela retangular deslizante w[n] o percorra para extrair características para inclusão no vetor de características f[n], cobrindo 0,125 ms em cada posicionamento, com sobreposição de 50% entre janelas consecutivas.

Qual é o comprimento de f[n]?
Quais são os valores em f[n], considerando a entropia ordinária, calculada com a base logarítmica β =10, como sendo a característica utilizada?

Solução:

Dados:

S[n]={-1,2,-3,3,2,1,-1,-1,-4,5,5,4}
Fs = 16.000 amostras/s
Janela retangular w[n]: Tw=0,125 ms e 50% entre janelas consecutivas.

1) Qual é o comprimento de f[n]?

Fs=16K amostras/s

Período de amostragem = Ts

Ts = 1/16K amostras/s

Duração da janela = Tw = 0,125 ms

L = O número de amostras por janela

L=Tw/Ts = 0.125 ms / (1/16)K = 0,125 . 16 = 2 **L=2 amostras por janela**.

Calculando a Sobreposição e o Deslocamento da Janela (Hop Size).

Sobreposição de 50%
Sobreposição em amostras: 0,50 x L = 0,50 x 2 = 1 amostra.
Deslocamento da janela (S=Hop Size):
S = L- sobreposição = 2-1 =1 amostra.

Calculando o Comprimento do Vetor de Características f[n] (Número de Janelas)

O comprimento de s[n] é N=12 amostras.
A fórmula para o número de janelas (W) é:

W = ⌊(N−L)/S⌋+1 onde ⌊ é chamado de "piso" ou "floor function". A função piso retorna o maior número inteiro ou como chamamos de arrendodamento de um número para baixo.

W = ⌊(12−2)/1⌋+1= 11

Portanto:

comprimento de f[n] = 11.

2) Quais são os valores de f[n]?

f[n] = Entropia (H) ordinária base 10

$$H=-\sum_{i=0}^{K-1} p_i \log_\beta (p_i)$$

H = Entropia, β= base do log e pi = é a probabilidade de ocorrência de cada valor único.

Olhando o sinal S[n]={-1,2,-3,3,2,1,-1,-1,-4,5,5,4}
β=10

Na entropia podemos pegar os valores que não se repete, no nosso caso do sinal completo, (-1,1,2, -3,3,-4,4,5) e checar quantas vezes ele aparece e aplicar na fórmula de entropia. Os sinais foram considerados porque se trata de **entropia ordinária**.
Portanto o mais fácil é usar a quantidade de janela que foi de 11, com 2 amostras e deslocamento sucessivo de 1 amostra.
f[n] foi considerado neste caso, a entropia característica, se fosse por exemplo a **energia de cada janela**, então os valores em f[n] seriam diferentes.

Calculando a entropia para as 11 janelas:

- **Janela 1**: **s[0], s[1] = {−1, 2} -> f[o]**

Valores únicos: -1, 2

Identificar os valores únicos na janela: Os valores presentes nesta janela são -1 e 2. São dois valores distintos.

Calcular a probabilidade de cada valor único:
O comprimento da janela (L) é 2 amostras.
O valor -1 aparece 1 vez na janela.
O valor 2 aparece 1 vez na janela.
Probabilidade de -1 (P(-1)): Número de ocorrência de -1 /Total de amostras da janela = ½ = 0,5.
Probabilidade de 2 (P(2)): Número de ocorrência de 2 /Total de amostras da janela = ½ = 0,5.

Aplicar a fórmula da Entropia: A fórmula da entropia. Neste caso, β=10

$H1=-[P(-1)\log_{10}(P(-1))+P(2)\log_{10}(P(2))]$
$H1=-[(0.5)\log_{10}(0.5)+(0.5)\log_{10}(0.5)]$

Calcular o logaritmo: $\log_{10}(0.5)\approx-0.30103$

Finalizar o cálculo: $H1=-[(0.5)\times(-0.30103)+(0.5)\times(-0.30103)]$
$H1=-[-0.150515+-0.150515]$
$H1=-[-0.30103]$
$H1=0.30103$
Assim, a entropia para a Janela 1 é aproximadamente 0.30103 ou diretamente

$H1=-((1/2)\log_{10}(1/2)+(1/2)\log_{10}(1/2))=-\log_{10}(0.5)\approx0.30103$

- **Janela 2: s[1], s[2] = {2, −3} -> f[1]**

  Mesma probabilidade.
  $H2=-\log10(0.5)\approx0.30103$

- **Janela 3: s[2], s[3] = {−3, 3} -> f[2]**

  Mesma probabilidade
  $H3=-\log10(0.5)\approx0.30103$

- **Janela 4: s[3], s[4] = {3, 2} -> f[3]**

  Mesma probabilidade
  $H4=-\log10(0.5)\approx0.30103$

- **Janela 5: s[4], s[5] = {2, 1} -> f[4]**

  Mesma probabilidade
  $H5=-\log10(0.5)\approx0.30103$

- **Janela 6: s[5], s[6] = {1, −1} -> f[5]**

  Mesma probabilidade
  $H6=-\log10(0.5)\approx0.30103$

- **Janela 7: s[6], s[7] = {−1, −1} –> f[6]**

Valores únicos: -1
$P(-1)=2/2=1$
$H7=-(1\times\log10(1))=-(1\times0)=0$

- **Janela 8: s[7], s[8] = {−1, −4} -> f[7]**

  Mesma probabilidade
  $H8=-\log10(0.5)\approx0.30103$

- **Janela 9: s[8], s[9] = {−4, 5} –> f[8]**

  Mesma probabilidade
  $H9=-\log10(0.5)\approx0.30103$

- **Janela 10: s[9], s[10] = {5, 5} -> f[9]**

  Valores únicos: 5
  $P(5)=2/2=1$
  $H10=-(1\times\log10(1))=-(1\times0)=0$

- **Janela 11: s[10], s[11] = {5, 4} - > f[10]**

  Mesma probabilidade
  $H11=-\log10(0.5)\approx0.30103$

Resultados Finais:

O comprimento de f[n] é **11**.
Os valores em f[n] são pegando os valores da entropia.

f[n]={0.30103,0.30103,0.30103,0.30103,0.30103,0.30103,0,0.30103,0.30103,0,0.30103}

(6): Explain, in a short paragraph, the concept of Bark scale. Why is it important?

Tradução: Explique, em um breve parágrafo, o conceito da escala Bark. Por que ela é importante?

Solução:

A escala Bark é uma escala psicoacústica de frequência que se baseia na percepção humana de altura (tom) e na forma como o ouvido humano agrupa frequências, sendo que ouvimos de 20Hz a 20Khz.

Ela divide o espectro audível em 24 "bandas críticas", onde cada banda crítica representa uma faixa de frequência em que o ouvido humano processa sons de forma similar.

Em termos mais simples, um incremento igual na escala Bark corresponde aproximadamente a um incremento igual na distância percebida entre os tons, o que não acontece na escala de frequência linear (Hertz).

Ela é usada em processamento de áudio, processamento de fala e acústica.

(7): Estimate the 4rd order LPC coefficients {a1, a2, a3, a4} for the signal y[n] = {2, 5, 2, 3, 5, 8, 4, 8, 10, 6}.

Tradução: Estime os coeficientes LPC de 4ª ordem {a1, a2, a3, a4} para o sinal y[n] = {2, 5, 2, 3, 5, 8, 4, 8, 10, 6}.

Solução:

LPC (Linear Predictive Coding) de **4ª** ordem.

O método dos mínimos quadrados é o princípio subjacente que permite estimar os parâmetros do modelo LPC, garantindo que a predição do sinal seja a mais precisa possível sob o critério de erro quadrático mínimo.
Uso 4 parâmetros para estimar o quinto.

O modelo de predição linear para uma amostra y[n] (**LPC**) usando P=4 coeficientes é:

e[n]= y[n] + a1y[n−1] + a2y[n−2] + a3y[n−3] + a4y[n-4]
ou
-y[n]= a1y[n−1] + a2y[n−2] + a3y[n−3] + a4y[n-4] – e[n]

Essa notação y[n−k] significa que a saída atual y[n] depende de valores passados do próprio sinal. Isso é chamado de **filtro recursivo** ou **IIR (Resposta Impulsiva Infinita)**, e também é a base da **predição linear**, onde tenta prever o valor atual com base em valores que já aconteceram e desloca de 1 unidade.

Como a ordem é **P=4**, a predição requer 4 amostras anteriores. Portanto, podemos começar a formar equações a partir de **n=5** por ser predito usando n=4,n=3,n=2 e n=1. Assim, teremos equações para n=5,6,7,8,9 e 10.

y[n] = {2, 5, 2, 3, 5, 8, 4, 8, 10, 6}

y[1]=**2** y[2]=**5** y[3]= **2** y[4]=**3** y[5]=**5** y[6]= **8** y[7]=**4** y=[8]=**8** y[9]=**10** y[10]=**6**

Portanto, a matriz A seria:

$$A = \begin{bmatrix} 3 & 2 & 5 & 2 \\ 5 & 3 & 2 & 5 \\ 8 & 5 & 3 & 2 \\ 4 & 8 & 5 & 3 \\ 8 & 4 & 8 & 5 \\ 10 & 8 & 4 & 8 \end{bmatrix}$$

Vetor dos Coeficientes LPC (a). Este vetor contém as incógnitas que queremos encontrar:

$$\mathbf{a} = \begin{bmatrix} a_1 \\ a_2 \\ a_3 \\ a_4 \end{bmatrix}$$

O vetor C contém os valores de −y[n] para cada equação correspondente:

$$\mathbf{C} = \begin{bmatrix} -5 \\ -8 \\ -4 \\ -8 \\ -10 \\ -6 \end{bmatrix}$$

Assim, o sistema de equações lineares para resolver os coeficientes LPC é **Aa=C**. $(A^TA)a=A^TC$

Assim, a matriz A^T é:

$$A^T = \begin{bmatrix} 3 & 5 & 8 & 4 & 8 & 10 \\ 2 & 3 & 5 & 8 & 4 & 8 \\ 5 & 2 & 3 & 5 & 8 & 4 \\ 2 & 5 & 2 & 3 & 5 & 8 \end{bmatrix}$$

Esta é a **equação normal** do Método dos Mínimos Quadrados. Ela transforma o sistema original superdeterminado (mais equações do que incógnitas) em um sistema quadrado (o mesmo número de equações e incógnitas) que pode ser resolvido para encontrar o vetor a que minimiza o erro quadrático.

A solução para a é então encontrada invertendo a matriz (A^TA) e multiplicando-a pelo vetor (A^TC):

$a=(A^TA)^{-1}(A^TC)$

Usando Gemini para calcular esta matriz, teremos:

a1 = 0.17466
a2 = 0.77190
a3 = 0.19830
a4 = - 0.19794

Usando a fórmula geral da função de transferência no domínio Z, temos que a função de transferência do modelo de produção de fala no LPC.

$$\frac{Y[z]}{E[z]} = \frac{1}{\left(1+a_1z^{-1}+a_2z^{-2}+a_3z^{-3}+...\right)}$$

A função de transferência do sistema que corresponde à resposta em frequência do trato vocal:

$$\boxed{H[Z] = \frac{1}{(1 + 0.17\,Z^{-1} + 0.77\,Z^{-2} + 0.20\,Z^{-3} - 0.20\,Z^{-4})}}$$

Existem outros métodos para resolver este sistema como: Decomposição QR, Decomposição de Cholesky, Métodos Iterativos (para grandes sistemas), Método do Gradiente Conjugado e Método de Gauss-Seidel e Método de Jacobi.

Alguns detalhes calculado pelo Gemini e Caht GPT, ambos dando os mesmos resultados:

A grande dúvida que ficou aqui é que uma matriz no Gemini foi montada como:

$$A = \begin{bmatrix} -y[4] & -y[3] & -y[2] & -y[1] \\ -y[5] & -y[4] & -y[3] & -y[2] \\ -y[6] & -y[5] & -y[4] & -y[3] \\ -y[7] & -y[6] & -y[5] & -y[4] \\ -y[8] & -y[7] & -y[6] & -y[5] \\ -y[9] & -y[8] & -y[7] & -y[6] \end{bmatrix}$$

E no CHATGPT como:

$$A_{alt} = \begin{bmatrix} -y[1] & -y[2] & -y[3] & -y[4] \\ -y[2] & -y[3] & -y[4] & -y[5] \\ -y[3] & -y[4] & -y[5] & -y[6] \\ -y[4] & -y[5] & -y[6] & -y[7] \\ -y[5] & -y[6] & -y[7] & -y[8] \\ -y[6] & -y[7] & -y[8] & -y[9] \end{bmatrix}$$

Com ordem invertida. Os resultados de a1,a2,a3 e a4 resultam diferentes.

Estudando o porque desta inversão chegamos que a sequência do Gemini está correta.

As amostras anteriores necessárias para **n=5 predito** temos:

- **y[n−1]=**y[5−1]=**y[4]**= 3
- **y[n−2]=**y[5−2]=**y[3]**= 2
- **y[n−3]=**y[5−3]=**y[2]**= 5
- **y[n−4]=**y[5−4]=**y[1]**= 2

Fazendo para n=10 temos:

- **y[n-1]** = y[10-1]=**y[9**] =10
- **y[n-2]=**y[10-2] = **y[8] =** 8
- **y[n-3]=**y[10-3]=**y[7] =** 4
- **y[n-4]=**y[10-4]=**y[6] =** 8

Os demais valores de n=6, 7, 8 e 9 é o mesmo procedimento.
Este conceito é fundamental para montar corretamente a matriz A.

Após esta análise, o ChatGPT concordou e recalculou dando os mesmos resultados.

(8): Explain the differences between, the advantages, and disadvantages of handcrafted features in comparison with those learned.

Tradução: Explique as diferenças, vantagens e desvantagens entre os recursos artesanais em comparação com aprendizado de máquina (IA).

Solução:

Características Artesanais (Handcrafted Features): São atributos ou propriedades de dados que são extraídos manualmente ou por algoritmos desenvolvidos por especialistas no domínio. A escolha e o design dessas características baseiam-se no conhecimento humano sobre o problema e os dados.
Por exemplo, em processamento de fala, formantes, pitch (frequência fundamental), MFCCs (Mel-Frequency Cepstral Coefficients). Em reconhecimento de imagem, histogramas de gradientes orientados (HOG), SIFT.

Aprendizado de Máquina: São atributos ou representações de dados que são automaticamente descobertos por algoritmos de aprendizado de máquina (especialmente redes neurais profundas) a partir dos próprios dados. O sistema aprende quais são as características mais relevantes para a tarefa diretamente dos exemplos fornecidos.
Os filtros e padrões que as camadas convolucionais em uma Rede Neural Convolucional (CNN) aprendem para tarefas de visão computacional, ou as representações de palavras em modelos de linguagem (word embeddings).

Vantagens das características artesanais:

- **Interpretabilidade:** Por serem projetadas por humanos, é mais fácil entender o que cada característica representa e por que ela é importante para o problema. Isso é crucial em domínios onde a explicabilidade é vital (e.g., medicina, finanças).
- **Menos Dados Necessários:** Como o conhecimento do domínio já está "embutido" no design da feature, elas geralmente exigem menos dados de treinamento para alcançar um desempenho razoável, especialmente em problemas com conjuntos de dados pequenos.
- **Eficiência Computacional:** A extração pode ser computacionalmente mais leve, pois são algoritmos diretos e frequentemente mais simples do que o treinamento de modelos complexos de aprendizado profundo.
- **Controle do Especialista:** Permitem que especialistas incorporem diretamente seu profundo conhecimento do problema no processo de extração de características.

Desvantagens das características artesanais:

- **Requer Conhecimento Especializado:** A criação dessas características depende fortemente da expertise humana. Sem um especialista no domínio, pode ser difícil ou impossível identificar características eficazes.

- **Consumo de Tempo e Trabalho Manual:** O processo de descoberta, design e implementação de características artesanais pode ser tedioso, demorado e sujeito a erros.
- **Potencial para Perder Informações Sutis:** As características projetadas por humanos podem não capturar todas as nuances e padrões complexos que estão presentes nos dados, especialmente aqueles que não são óbvios para o olho humano ou para o conhecimento existente.
- **Falta de Adaptabilidade:** Se o domínio do problema mudar ligeiramente ou se os dados tiverem variações inesperadas, as características artesanais podem se tornar menos eficazes e precisam ser redesenhadas.

O aprendizado de máquina por sua vez reduz a dependência de especialistas e são mais flexíveis e podem se adaptar a diferentes conjuntos de dados ou domínios e têm um grande potencial para generalizar bem para dados não vistos.
Porém requerem grande volume de dados, alto custo computacional, falta de Interpretabilidade pois é uma "caixa preta" onde entra e saí os resultados e tem Sensibilidade a Hiperparâmetros (taxa de aprendizado, arquitetura da rede, etc).

(9): Answer the first two **HMM λ** related questions on **page 99** for the weather-related model below, considering the observation sequence O = {rainy, sunny}.

Page 99: Basic questions involving HMMs are:

1) Given an observation sequence X and an HMM **λ**, how could we efficiently compute the probability of observing X considering the model,i.e., P(O/λ)?
   Solution: backward-forward algorithm.
2) Given an observation sequence X and an HMM λ, how could we find the best sequence of states and transitions to explain the observation?
   Solution: Viterbi's Algorithm.

Tradução:

Responda às duas primeiras perguntas relacionadas ao HMM λ na página 99 para o modelo relacionado ao clima abaixo, considerando a sequência de observação **O = {chuvoso, nublado}.**

Página 99: Questões básicas envolvendo HMMs são:

1) Dada uma sequência de observações X e um HMM λ, como poderíamos calcular eficientemente a probabilidade de observar X considerando o modelo, ou seja, P(O/ λ)?

Solução: algoritmo forward-backward.

2) Dada uma sequência de observações X e um HMM λ, como poderíamos encontrar a melhor sequência de estados e transições para explicar a observação?

Solução: Algoritmo de Viterbi.

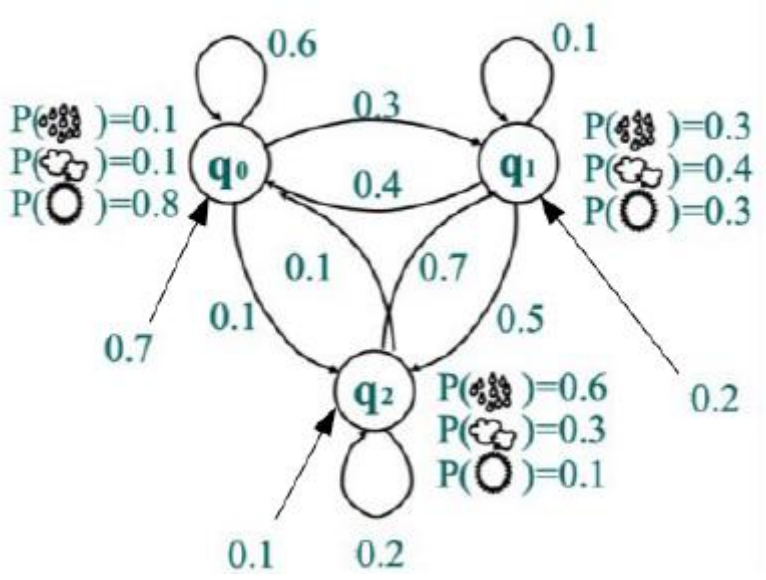

Solução 2: (confundi ensolorado com nublado, deixei a solução 2 descrito em detalhes e a solução 1 depois do final desta).

P(O/λ) = é a probabilidade de ver um conjunto de dados específicos, dada a maneira como você modelou o processo que supostamente gerou esses dados. É uma medida-chave para determinar o quão bem um modelo se "encaixa" nos dados observados.
O é a observação e **λ** é o modelo estatístico.
Lê -se Probabilidade da observação O (chuvoso/nublado) dado o modelo λ (HMM).

O modelo oculto de Markov (HMM) foi muito usado no passado (até 2015), hoje não é mais usado.

Explicando a figura:

Os circulos são fonemas e as setas representam o estado ou tempo. São fonemas com probabilidades de transições.
Em **q0** temos probabilidade de chuva=10%, probabilidade tempo nublado 10% e probabilidade de sol 90%.
A seta que vem do "nada" com valor de 70% indica ser a probabilidade de observação inicial ou estado inicial.
O loop nele mesmo de 60% indica a possibilidade de permanecer neste estado. Com 30% de probabilidade ele passa para outro estado **q1** e 10% a novo estado **q2**.
q1 e q2 tem a mesma explicação.
Portanto um gráfico de probabilidades onde a soma das porcentagens chegam a 100%.

Na questão **O = {chuvoso, nublado}**, significa em qual estado existe a probabilidade do tempo chuvoso passar a ser nublado depois de um tempo.

No nosso gráfico modelo temos 3 estados (q0, q1 e q2). Esta situação pode estar em qualquer estado ou misto deles, por exemplo, chuvoso em q1 e nublado em q2.

Para encontrar esta resposta, usamos a solução da primeira questão de HMM 1) algoritmo forward-backward.

Para modelos pequenos podemos usar a solução manualmente mas modelos grandes é melhor usar a IA (algortmos).

Manualmente a solução é de matrizes. Neste caso podemos usar a técnica de 3 matrizes, A, B e π.
A matriz π é de uma coluna e contém a probabilidade de ocorrer a observação O nos 3 estado. Trata-se da seta de fora que vem de lugar algum, no nosso caso 0.7, 0.2 e 0.1.

$$\pi = \begin{bmatrix} 0.7 \\ 0.2 \\ 0.1 \end{bmatrix}$$

A **matriz B** é formado cada coluna para cada estado q0, q1 e q2, que no nosso caso tem 3 situações probalilistica: chuva, nublado e sol.

$$B = \begin{bmatrix} 0.1 & 0.3 & 0.6 \\ 0.1 & 0.4 & 0.3 \\ 0.8 & 0.3 & 0.1 \end{bmatrix}$$

A **matriz A** pegamos a transição de um estado para outro para formar cada linha, sendo que **q0** forma a linha 1 **q1** a linha 2 e **q2** a linha 3.
Nota que a probabilidade de ficar nele mesmo, segue a coluna e de mudar de estado também segue a coluna.
Exemplo: 0.1 da linha 3 e coluna 1 e a mudança de estado de q2 para q0, 0.7 e a mudança de estado de q2 para o q1 e 0.2 e a mudança de estado para ele mesmo (loop).

$$A = \begin{bmatrix} 0.6 & 0.3 & 0.1 \\ 0.4 & 0.1 & 0.5 \\ 0.1 & 0.7 & 0.2 \end{bmatrix}$$

No nosso modelo podemos afirmar que:

P(O/λ) = (observação, **chuva**, **nublado**, **loop)**
P(O/λ) = **0.7***0.1* **0.1***0.6 + **0.2***0.3***0.4***0.1 + **0.1***0.6***0.3***0.2 e todas as possibilidades possíveis.

Probabilidade da observação O (chuvoso/nublado) dado o modelo λ (HMM) é igual a probablidade de observação q0 (preto) multiplicado pela probabilidade de chuva q0 (azul) multiplicado pela probabilidade de nublado q0 (vermelho) multiplicado pela probabilidade de ficar em um estado nele mesmo q0 (roxo) ou (+) (tudo de novo de q1) ou (repete para q2) e todas as possibilidades que existir.

OBS.: A soma dos valores de chuva e nublado não dá 100% porque existe a probabilidade de sol, não usado aqui.

Porém para evitarmos este trabalhão manual, usaremos o algoritmo **forward-backward** que é formado por 2 matrizes chamado de a (alfa) e β (beta).
A matriz alfa tera 2 linas e 3 colunas (2x3) porque estamos usando 2 pobabilidade de chuva ou nublado e temos 3 estados **a =(itens, estado).**

$$\alpha = \begin{bmatrix} a11 & a12 & a13 \\ a21 & a22 & a23 \end{bmatrix}$$

Onde:

a11= probabilidade de ser chuvoso no primeiro estado
a12 = probabilidade de ser chuvoso no segundo estado
a13 = probabilidade de ser chuvoso no terceiro estado

a21= probabilidade de ser nublad0 no primeiro estado
a22 = probabilidade de ser nublad0 no segundo estado
a23 = probabilidade de ser nublado no terceiro estado

a11 é calculado do mesmo procedimento que a12 e a13.

Aqui entra as matrizes **π, A e B.**

a11 = Probabilidade de observação multiplicado pela possibilidade de chuva. (π.chuva)

a21 é calculado do mesmo procedimento que a22 e a23.
a21 = Probabilidade de ser nublado multiplicando uma combinação linear de valores (elementos da linha anterior (a11,a12,a13)*coluna da matriz A)

$$\pi = \begin{bmatrix} 0.7 \\ 0.2 \\ 0.1 \end{bmatrix}$$

$$B = \begin{bmatrix} 0.1 & 0.3 & 0.6 \\ 0.1 & 0.4 & 0.3 \\ 0.8 & 0.3 & 0.1 \end{bmatrix}$$

$$A = \begin{bmatrix} 0.6 & 0.3 & 0.1 \\ 0.4 & 0.1 & 0.5 \\ 0.1 & 0.7 & 0.2 \end{bmatrix}$$

$$\alpha = \begin{bmatrix} a11 & a12 & a13 \\ a21 & a22 & a23 \end{bmatrix} \qquad \alpha = \begin{bmatrix} 0.07 & 0.06 & 0.06 \\ 0.7*0.1 & 0.2*0.3 & 0.1*0.6 \\ a21 & a22 & a23 \end{bmatrix}$$

a21 = 0.1 (0.07*0.6+0.06*0.4+0.06*0.1) = 0.1 (0.042+0.024+0.006) = 0,0072
a22 = 0.4 (0.07*0.3+0.06*0.1+0.06*0.7) = 0.4 (0.021+0.006+0.042) = 0.0276
a23 = 0.3 (0.07*0.1+0.06*0.5+0.06*0.2) = 0.3 (0.007+0.030+0.012) = 0.0147

$$\alpha = \begin{bmatrix} 0.07 & 0.06 & 0.06 \\ 0.0072 & 0.0276 & 0.0147 \end{bmatrix}$$

$$\alpha = \begin{bmatrix} 0.07 & 0.06 & 0.06 \\ 0.0072 & 0.0276 & 0.0147 \end{bmatrix}$$

Da matriz alfa se eu somar os elementos da segunda linha, teremos **P(O/λ).**

P(O/λ) = 0.0072 + 0.0276 + 0.0147

P(O/λ) = 0.0495 - Que é a resposta da primeira pergunta.
A sequência de observações (chuvoso, nublado) a probabilidade P(O/λ)=0.0495

Para responder a pergunta 2, usaremos o logaritmico de Viterbi.
Para isso iremos trabalhar com a matriz beta (β) para formar a matriz gamma (γ) nas mesmas dimensões que a matriz alfa (a).

A primeira linha de β são os mesmos elementos da primeira linha de a.
A primeira linha de γ por definição é preenchida com zeros.

A segunda linha da matriz β é formada com a seguinte lógica:

a) Pega apenas combinação linear que foi usada na matriz a e onde existia (+) coloca (;)
b) Dos 3 valores da combinação linear identifica o maior valor.
No nosso caso **0.042,** 0.021 e 0.030

Para completar a segunda linha da matriz γ eu coloco qual a posição de cada elemento foi o valor maior da combinação. No nosso caso cada combinação tinha 3 posições (1,2,3) equivalente a (q0,q1,q2) e são estas posições que eu coloco, correspondente ao maior valor usado em β.
Assim a matriz γ tem os índices dos maiores valores contidos na matriz β.
No nosso caso indice **1, 1 e 2**
Agora se eu pegar a última linha de beta, a probabilidade do melhor caminho é o valor maior.

$P_{melhor\ caminho}$ = 0.042 de a21

Para descobrir qual o melhor caminho de estados, definir um conjunto onde se tira o argumento máximo em 2 estados, pois temos a chuva e o nublado.
A **chuva** vem de um estado q0, q1 ou q2 e o **nublado** vem de outro estado que também pode ser q0, q1 ou q2.

O melhor caminho que escolhe os 2 estados é preenchido da direita para a esquerda ou do fim para o começo.

Melhor camimho estado (Q) = {c2 [estado da chuva**], c1 [**estado do nublado**]}**

c1 = olhando a matriz β veremos qual o índice do elemento maior. No nosso caso 1

c2 = olhando a matriz γ vejo qual o valor que está na coluna indicada pelo índice do valor c1 que no nosso caso é 1 .

Portanto temos o melhor caminho de estado da chuva e nublado entre todas as possibilidades possíveis:

Q=(1,1) = estado 1 chuvoso e nele mesmo fica nublado.
Sendo a respotsa da segunda pergunta, portanto estado q0.

Colocando as expressões descritas acima:

$$\pi = \begin{bmatrix} 0.7 \\ 0.2 \\ 0.1 \end{bmatrix}$$

$$B = \begin{bmatrix} 0.1 & 0.3 & 0.6 \\ 0.1 & 0.4 & 0.3 \\ 0.8 & 0.3 & 0.1 \end{bmatrix}$$

$$A = \begin{bmatrix} 0.6 & 0.3 & 0.1 \\ 0.4 & 0.1 & 0.5 \\ 0.1 & 0.7 & 0.2 \end{bmatrix}$$

$$\beta = \begin{bmatrix} a11 & a12 & a13 \\ a21 & a22 & a23 \end{bmatrix} \quad \beta = \begin{bmatrix} 0.07 & 0.06 & 0.06 \\ \mathbf{0.057} & \mathbf{0.069} & \mathbf{0.004} \end{bmatrix}$$

$$\gamma = \begin{bmatrix} b11 & b12 & b13 \\ b21 & b22 & b23 \end{bmatrix} \quad \gamma = \begin{bmatrix} 0 & 0 & 0 \\ \mathbf{1} & \mathbf{1} & \mathbf{2} \end{bmatrix}$$

a21 = (0.07*0.6 ; 0.06*0.4 ; 0.06*0.1) = maior (**0.042**+0.024+0.006) = 1
a22 = (0.07*0.3 ; 0.06*0.1 ; 0.06*0.7) = maior (**0.021**+0.006+0.042) = 1
a23 = (0.07*0.1 ; 0.06*0.5 ; 0.06*0.2) = maior (0.007+**0.030**+0.012) = 2

$P_{melhor\ caminho}$ = **0.057** de a21

Q (c2,c1)

c1 = índice arg. Máximo dentro dos elementos da matriz β = 1
c2 = olhando a última linha da matriz Y qual o valor estão no índice dado por c1 = 1 , no nosso caso = 1

$\boxed{Q\ (1,1)}$

Solução 1:

O = {chuvoso, ensolorado} - forward-backward

$$\pi = \begin{bmatrix} 0.7 \\ 0.2 \\ 0.1 \end{bmatrix}$$

O(Chuva, Sol)

$$B = \begin{bmatrix} 0.1 & 0.3 & 0.6 \\ 0.1 & 0.4 & 0.3 \\ 0.8 & 0.3 & 0.1 \end{bmatrix}$$

$$A = \begin{bmatrix} 0.6 & 0.3 & 0.1 \\ 0.4 & 0.1 & 0.5 \\ 0.1 & 0.7 & 0.2 \end{bmatrix}$$

$$\alpha = \begin{bmatrix} a11 & a12 & a13 \\ a21 & a22 & a23 \end{bmatrix} \quad \alpha = \begin{bmatrix} 0.07 & 0.06 & 0.06 \\ 0.7*0.1 & 0.2*0.3 & 0.1*0.6 \\ a21 & a22 & a23 \end{bmatrix}$$

a21 = 0.8 (0.07*0.6+0.06*0.4+0.06*0.1) = 0.8 (0.042+0.024+0.006) = 0,0576
a22 = 0.3 (0.07*0.3+0.06*0.1+0.06*0.7) = 0.3 (0.021+0.006+0.042) = 0.0207
a23 = 0.1 (0.07*0.1+0.06*0.5+0.06*0.2) = 0.1 (0.007+0.030+0.012) = 0.0049

$$\alpha = \begin{bmatrix} 0.07 & 0.06 & 0.06 \\ 0.0576 & 0.0207 & 0.0049 \end{bmatrix}$$

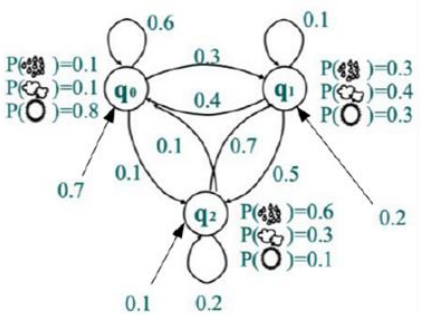

P(O/λ) = 0.0576 + 0.0207 + 0.0049

P(O/λ) = 0.0832 - Que é a resposta da primeira pergunta.
A sequência de observações (chuvoso, ensolarado) a probabilidade P(O/λ)=0.0832

$$\pi = \begin{bmatrix} 0.7 \\ 0.2 \\ 0.1 \end{bmatrix}$$

$$B = \begin{bmatrix} 0.1 & 0.3 & 0.6 \\ 0.1 & 0.4 & 0.3 \\ 0.8 & 0.3 & 0.1 \end{bmatrix}$$

$$A = \begin{bmatrix} 0.6 & 0.3 & 0.1 \\ 0.4 & 0.1 & 0.5 \\ 0.1 & 0.7 & 0.2 \end{bmatrix}$$

$$\beta = \begin{bmatrix} a11 & a12 & a13 \\ a21 & a22 & a23 \end{bmatrix} \quad \beta = \begin{bmatrix} 0.07 & 0.06 & 0.06 \\ 0.057 & 0.069 & 0.004 \\ 6 & 0 & 9 \end{bmatrix}$$

$$Y = \begin{bmatrix} b11 & b12 & b13 \\ b21 & b22 & b23 \end{bmatrix} \quad Y = \begin{bmatrix} 0 & 0 & 0 \\ 1 & 1 & 2 \end{bmatrix}$$

1

a21 = (0.07*0.6 ; 0.06*0.4 ; 0.06*0.1) = maior (**0.042**+0.024+0.006) = 1
a22 = (0.07*0.3 ; 0.06*0.1 ; 0.06*0.7) = maior (**0.021**+0.006+0.042) = 1
a23 = (0.07*0.1 ; 0.06*0.5 ; 0.06*0.2) = maior (0.007+**0.030**+0.012) = 2

$P_{melhor\ caminho}$ = **0.057** de a21

Q (c2,c1)

c1 = índice arg. Máximo dentro dos elementos da matriz β = 1
c2 = olhando a última linha da matriz Y qual o valor estão no índice dado por c1 = 1 , no nosso caso = 1

$\boxed{Q\ (1,1)}$

Q=(1,1) = estado 1 chuvoso e nele mesmo fica ensolorado.
Sendo a resposta da segunda pergunta, portanto estado q0.

(10): Given the template model for classes CA and CB, i.e., {0.2, 1, 0.7} and {0.3, 0.9, 0.8}, respectively, find the best matching class for the testing signal t[n] = {0.2, 0.9, 0.9} by using the ordinary Euclidian distance metric. What would you do to find that match in case the testing signal and the template models have different dimensions?

Tradução: Dado o template de modelo para as classes CA e CB, ou seja, {**0.2**, 1, **0.7**} e {**0.3**, 0,9, **0.8**}, respectivamente:

1) Encontre a melhor classe correspondente para o sinal de teste **t[n] = {0.2**, 0.9, **0.9}** usando a métrica de **distância euclidiana ordinária**.
2) que você faria para encontrar essa correspondência caso o sinal de teste e os Template de modelo tenham dimensões diferentes?

Solução:

Para a pergunta 1) temos:

A distância euclidiana entre dois pontos P=(p1,p2,...,pn) e Q=(q1,q2,...,qn) em um espaço n-dimensional é dada pela fórmula:

$$D(P,Q) = \sqrt{(p_1 - q_1)^2 + (p_2 - q_2)^2 + ... + (p_n - q_n)^2}$$

A distância entre o sinal t[n] e CA ficaria:

$$\begin{aligned}
D(t[n], CA) &= \sqrt{(0.2 - 0.2)^2 + (0.9 - 1)^2 + (0.9 - 0.7)^2} \\
D(t[n], CA) &= \sqrt{(0)^2 + (-0.1)^2 + (0.2)^2} \\
D(t[n], CA) &= \sqrt{0 + 0.01 + 0.04} \\
D(t[n], CA) &= \sqrt{0.05} \\
D(t[n], CA) &\approx 0.2236
\end{aligned}$$

A distância entre t[n] e CB está mostrado abaixo:

$$D(t[n], CB) = \sqrt{(0.2 - 0.3)^2 + (0.9 - 0.9)^2 + (0.9 - 0.8)^2}$$
$$D(t[n], CB) = \sqrt{(-0.1)^2 + (0)^2 + (0.1)^2}$$
$$D(t[n], CB) = \sqrt{0.01 + 0 + 0.01}$$
$$D(t[n], CB) = \sqrt{0.02}$$
$$D(t[n], CB) \approx 0.1414$$

A distância entre o sinal t[n] e sinal CA = 0.2236 e entre t[n] e CB= 0.1414.
O sinal CB aplicando a fórmula direta e simples da métrica de distância euclidiana ordinária em relação ao sinal t[n] é a menor e portanto é a melhor classe.

A melhor classe é o sinal CB.

Para a pergunta 2) temos:

Se o template de modelos tiver tamanhos diferentes, podemos usar o método **Dynamic TimeWarping (DTW) Classifier.**

Aqui encerra a resposta do exercício 10 mas o método DTW foi usado e explicado em detalhes para estes sinais.
A princípio pensei que seria este o método solicitado e somente depois percebi a simplicidade da resposta.
Portanto deixei a resolução neste método, que tem sua complexidade de entendimento mas simples de fazer e que traria resultados para tamanhos diferentes de templates.

O classificador Dynamic Time Warping (DTW) é bem modesto. Ele compara dois sinais e não retira características. A particularidade deste classificador é que ele trabalha com sinais de tamanhos **iguais e diferentes**.

Temos o sinal **CA={0.2,1,0.7**} com 3 parâmetros e **CB={0.3, 0.9, 0.8}** também com 3 parâmetros.
O nosso sinal de comparação é: t[n]={0.2, 0.9, 0.9}.

Então faremos a comparação entre t[n] com CA e t[n] com CB.

A comparação é realizada usando 3 matrizes para comparar t[n] com CA.
Esta matriz é como se fosse uma tabela, então usar o excell facilita as coisas.
Usaremos o conceito de plano cartesiano, ou seja, no eixo X eu vou colocar o sinal t[n] e no eixo Y vou colocar o sinal CA. Portanto a matriz terá o tamanho dos sinais,no nosso caso uma matriz quadrado 3x3, onde t[n] define o tamanho das colunas e CA p tamanho das linhas.

A figura 6 mostra todos os passos.

A **primeira matriz** ou tabela, cada elemento conterá a distância de um elemento para outro em **módulo**.
Esta distância é marcada cada elemento da linha no plano y (CA) com o elemento de coluna no plano X (t[n]), portanto a distância do par ordenado **(linha,coluna)**. Por exemplo: No nosso caso a primeira linha foi preenchido desta forma:
linha 1 e coluna 1 a distância é **0** devido o par ordenado (0.2, 0.2)
Linha 1 e coluna 2 a distância é **0.7** devido par ordenado (0.2,0.9)
Linha 1 e coluna 3 a distância é **0.7** devido par ordenado (0.2,0.9)

A **segunda matriz** terá a mesma dimensão da primeira. Ela é conhecida como Distância acumulada AccDist.
Os seus elementos são formados no processo chamado **L**, sempre preenchendo 1 linha e 1 coluna até que preenche tudo, conforme o desenho abaixo.
Nosso exemplo é simples, tem apenas 2 L formados.

Figura 5 - ACCDIST - Distância Acumulada

b2	b3	b4
b1	a4	a5
a1	a2	a3

Para preencher a linha do plano X no quadrado a1 eu pego o valor da mesma posição da primeira tabela e somo com o vizinho da **esquerda**, a1=0+0.2 =0.2.
Para formar o a2 eu pego o valor que está na tabela de cima e somo com seu vizinho da mesma tabela da esquerda: a2=a1+valor da tabela de cima da mesma posição = a2=0.7+0.2 = 0.9 .O a3 é a mesma sequência: a3=a2+valor da tabela de cima mesma posição, a3=0.7+0.9= 1.6.

Pra preencher as lacunas de b1 e b2, o sistema é parecido, apenas devemos pegar o valor que está na primeira tabela e somar com o vizinho de **baixo**.
b1= 0.8 + valor da primeira tabela mesma posição b1=0.8+0.2 = 1.0 e b2=0.5 + 1.0 = 1.5.

Terminado o primeiro L em verde da figura 5, partimos para o segundo L em laranja. Aqui muda o conceito do complementar.
O a4 = valor da primeira matriz na mesma posição=0.1
Porém eu devo somar com seu vizinhos que tem menor valor. No caso temos os valores 1 , 0.2 e 0.9. O menor valor é 0.2 portanto a4= 0.1 + 0.2 = 0.3
a5 = 0.1 _ menor valor dos 3 vizinhos = 0.1 + 0.3 = 0.4 e b3=0.2 + 0.3 = 0.5

Acabou os L. Então preencho com o valor de final no mesmo procedimento, ou seja, se fosse iniciar um novo L, eu somaria o valor que está na mesma posição com o menor membro dos 3 vizinhos. Então b4 = 0.2 + 0.3 = 0.5

A terceira tabela tem as mesmas dimensões, chamado de Best Path ou melhor caminho. Ela é preenchida com uma das 3 setas possíveis (para cima, para a direita e a 45° inclinada).

Apenas uma posição do cruzamento 0,0 do plano cartesiano eu coloco um ponto, local neutro.
As demais posições eu coloco setas.
Sempre o primeiro L teve a contribuição dos valores da esquerda no plano X e de baixo do plano Y. Portanto as setas neste L será mostrando esta contribuição, seta para direita e seta para cima.
A posição a4 eu verifico qual dos 3 vizinhos contribuiram. No nosso caso foi o valor 0.2 e a seta de quem contribuiu fica inclinada de 45°.
A posição a5 tivemos a contribuição do 0.3 portanto a seta fica para direta.
A posição b3 tivemos a contribuição 0.3 portanto a seta fica para cima.
A posição b4 tivemos a contribuição 0.3 portanto a seta fica inclinada.
Uma vez indicada as setas, eu pego sempre a posição mais da direita e supeior da matriz, no nosso caso é a posição b4.
Sinalizo esta posição, no nosso caso com bordas vermelhas.
Caminho para o próxima posição no sentido contrário da seta e faço o mesmo.
Caminho novamente e chego na posição inicial.
Conto quantas posições foram marcadas.
No nosso caso foram 3 e esta marcação mostra o melhor caminho seguido.

Figura 6 - Comparando t[n] com sinal CA

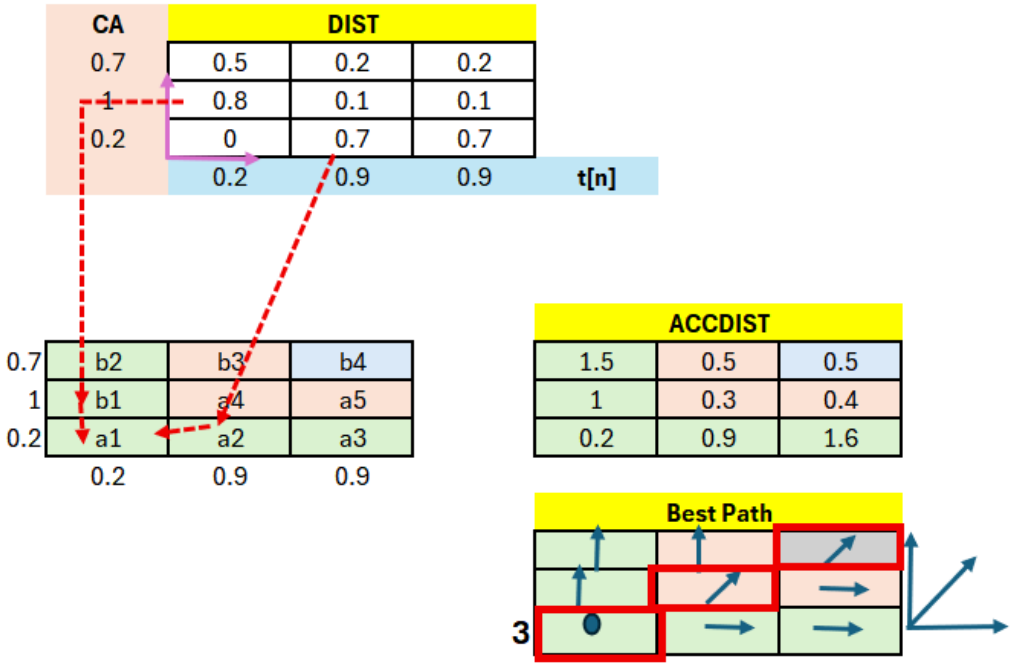

Agora devo fazer a mesma coisa, comparando t[n] com CB.

Na posição do elemento b4 a contribuição com menor valor foi 0.4 que veio de baixo ou inclinado.
Sempre que tiver a disputa do inclinado com outra posição para cima ou direita, a preferência é do inclinado.
Portanto deu a mesma coisa que o caminho ou seja **caminho CA=caminho CB**.

Figura 7 - Comparação do sinal t[n] com sinal CB

CB	DIST			
0.8	0.6	0.1	0.1	
0.9	0.7	0	0	
0.3	0.1	0.6	0.6	
	0.2	0.9	0.9	t[n]

	ACCDIST		
0.8	1.7	0.5	0.5
0.9	1.1	0.4	0.4
0.3	0.4	1	1.6

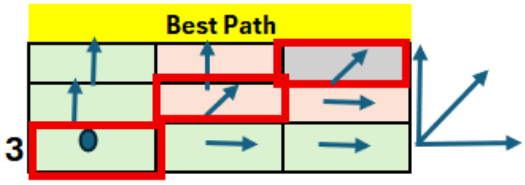

Conclusão: Comparando DTW=3 para CA e mesmo valor para CB, nestes sinais não teríamos nenhum resultado de melhor classe, que no caso sempre será a classe com menor valor.
Cabe aqui outra observação que esta comparação poderia na prática verificar o template e valores e chegar na conclusão que mesmo o menor valor estaria longe do template e portanto ambas podiam ser rejeitadas com oclasses parecidas.
Porém como usamos o método **distância euclidiana ordinária**, que serve para sinais ou vetor de mesmo tamanho (dimensão), que é o nosso caso, chegamos na conclusão que o melhor sinal é o CB.
Se fossem diferentes, além do DTW poderíamos também usar o HMM estudado ou retirar algumas características e comparar.

END

Esta avaliação firmou conhecimento de :

1 – Filtros Digitais tipo FIR, usando o filtro passa baixa como base para todos os outros tipos de filtros.
2 – Os sinais que passam pelo filtro tem uma janela de avaliação com características diferentes para mitigar os efeitos Gibbs.
3 – Podemos usar as análise dos sinais no tempo ou na frequência, através da transformada de Fourrier e Laplace.
4 - Função de Transferência com pólos e zeros. Conhecido como Ganho ou curva de Bode.
5- Correlação e auto-correlação de sinais.
6 – Analisar sinais e buscar características, comparações e classificações. Os métodos mais comuns utilizados.