IX INTEGRAÇÃO DE SABERES AMBIENTAIS:
CIDADES INTELIGENTES & SUSTENTÁVEIS
02/10 03/10 04/10 2024

TROUBLESHOOTING SMT/TEST LINE WITH ARTIFICIAL INTELLIGENCE (TSTAI)

Levi Rodrigues da Silva[1]; Rodrigo Capobianco Guido[2]
1 UNESP-ICTS, e-mail: levi.silva@unesp.br ; 2 UNESP - ICTSJBV

Introdução

Indústrias que produzem ferramentas, brinquedos, acessórios/utensílios domésticos e bens de consumo, todos eletrônicos, usam a automação de uma linha de produção chamada SMT ou *Front End*. O resultado dessa produção são PCBA com funções pré-determinadas. Essas placas são testadas para serem montadas em seu gabinete ou chassi. Essa fase da produção é conhecida como *Back End*.

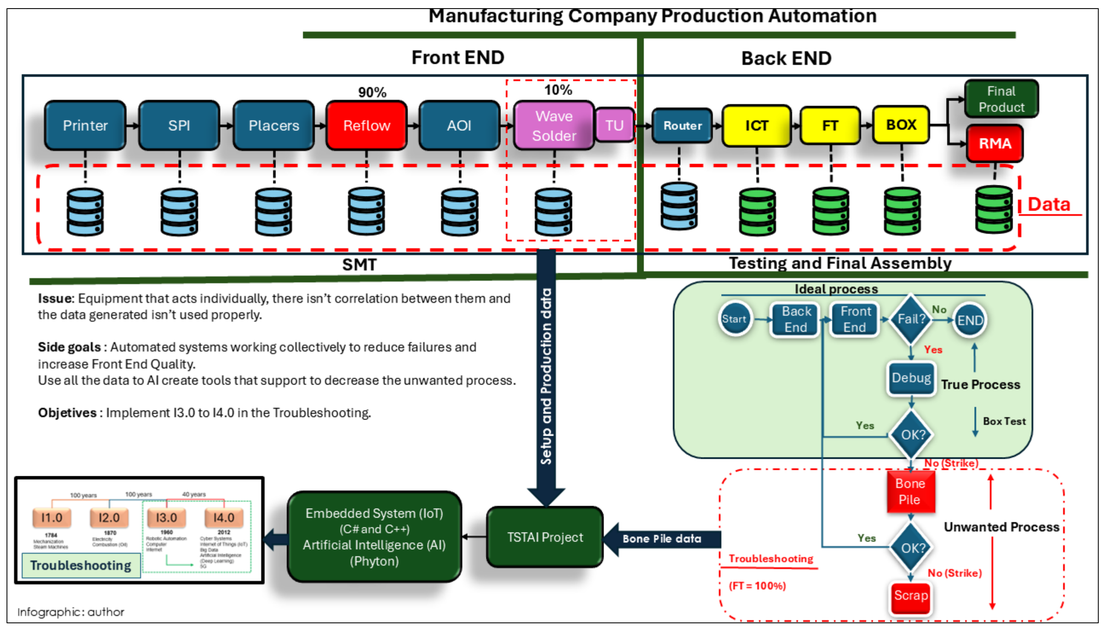

As PCBAs com falhas são recuperadas ou levadas à *scrap*. A indústria de manufatura tem trabalhado pela possibilidade de eliminar alguns testes de PCBA. Através do projeto **TSTAI** pode-se diminuir testes/scrap que não agregam valor ao produto e assim poder atingir o status de I4.0 através do IA e sistemas embarcados.

Metodologia

São quatro tarefas necessárias para completar todas as etapas deste projeto:

1. Obter conhecimentos (*Know How*) das ferramentas necessárias para aplicação no projeto e habilidade para implementar elas;
2. Acessar banco de dados *setup*/produção dos equipamentos automatizados do SMT/Testes e preparar eles para uso de IA;
3. Empregar a metodologia especificada da Inteligência Artificial : **IA-*Machine Learning*-*Deep Learning* -Regressão Logística/Classificação**;
4. Analisar respostas do IA e separar os principais resultados para buscar ferramentas de Hardware (HW) e Software (SW) que repliquem processos que diminuem a quantidade de PCBA para análise de falhas e scrap.

Resultados e Discussão

Os conhecimentos e habilidades estão sendo adquiridos em disciplinas rigidamente selecionadas na PGEE-ICTS.

Paralelamente buscar a parceria de indústrias do ramo de Companhia de Manufatura (CM). A maior dificuldade até o momento é encontrar esta parceria ou banco de dados similares e públicos para iniciar os trabalhos de limpeza, filtros dos ruídos e iniciar a tratativa e vários métodos diferentes da IA nos **banco de dados** para selecionar um processo maduro e sólido.

Conclusão

A maior das dificuldades é obter os bancos de dados. O ambiente de trabalho é outro problema grave. Disponíveis em *cloud* pode não ser o suficiente para o treinamento dos dados (*Machine Learn*). É um projeto desafiador e necessário para as indústrias que desejam alcançar a I4.0 através do sistema embarcado (Iot das coisas) e IA para *troubleshooting*.

Agradecimentos

Na ciência necessitamos de ser obstinado e resiliente e para isso a fé e crença tem um forte argumento, portando, agradecemos a Deus por nos proporcionar tão bem o que desejamos.

À UNESP pela oportunidade deste trabalho, nosso orientador de projeto Rodrigo Capobianco Guido e para a família que não mede esforços de apoio na criação de ambientes e oportunidades de gerir o pouco tempo que são destinados a eles.

Referências

ABNT, NBR 6023:2018.

L. Molina-Fernandez, D. Arias-Aranda, and O. Bustiza-S´anchez, "Industry 4.0 and competitive advantage. an analysis.

Antonio Gulli, Amita Kapoor, and Sujit Pal, Deep Learning with TensorFlow 2 and Keras, Packt, 2019