INTERPOLAÇÃO PARA FALHAS EM SÉRIE DE DADOS METEOROLÓGICOS

RESUMO

O monitoramento de dados meteorológicos é fundamental para diversas áreas de estudo, desde o planejamento urbano até a pesquisa em ciências ambientais. Neste contexto, a Estação Meteorológica de Sorocaba, identificada como V0498 pelo Instituto Nacional de Meteorologia (INMET), desempenha um papel crucial. Esta estação é fruto de uma parceria estratégica entre o INMET e a FATEC Sorocaba, contando com a valiosa contribuição do Prof. Dr. José Carlos Ferreira.
O projeto da UNESP intitulado "Análise Embarcada de Dados de Temperatura e Umidade da Área de Preservação Permanente do Ibiti Royal Park" é um exemplo que utiliza estes dados como pilar metodológico.
A coleta e o tratamento dos dados seguiram rigorosamente as normas e os procedimentos estabelecidos pelo INMET, garantindo a precisão e a confiabilidade necessárias para as análises subsequentes.
Falhas na Estação resultam na interrupção da coleta de dados. A solução proposta é a **interpolação de dados** de estações próximas para o **preenchimento das lacunas** geradas.

ABSTRACT

Monitoring meteorological data is essential for various fields of study, ranging from urban planning to environmental science research. In this context, the Sorocaba Meteorological Station (V0498), managed by the National Institute of Meteorology (INMET), plays a crucial role. This station is the result of a strategic partnership between INMET and FATEC Sorocaba, significantly supported by Prof. Dr. José Carlos Ferreira.
For instance, the UNESP project, 'Onboard Analysis of Temperature and Humidity Data from the Permanent Preservation Area of Ibiti Royal Park,' uses this data as its methodological basis.
Data collection and processing strictly adhered to the norms and procedures established by INMET, thereby ensuring the necessary precision and reliability for subsequent analyses.
However, station failures often interrupt data collection. The proposed solution is to use data interpolation from nearby stations to fill the resulting gaps

OBJETIVOS

Desenvolver e aplicar um método de interpolação espacial para recuperar e imputar dados meteorológicos faltantes (*gaps*) na série temporal da Estação Meteorológica de Sorocaba, utilizando registros de estações vizinhas.

INTRODUÇÃO

A premissa da Primeira Lei da Geografia de Tobler fundamenta este estudo, que aborda um desafio comum em medições contínuas: a **perda de dados**.
Uma falha operacional na Estação Meteorológica V0498, crucial para um projeto da UNESP, resultou na **perda permanente de uma série temporal**.
Diante da ausência de uma solução de recuperação padronizada, esta pesquisa propõe o **desenvolvimento de um programa de Interpolação Espacial**.
O método Inverso da Distância Ponderada (**IDW**) será utilizado, baseando-se em estações próximas, para imputar os dados omissos com precisão.

O projeto visa tanto fornecer uma **solução local imediata** quanto gerar uma documentação técnica replicável, alinhada à filosofia Kaizen.

METODOLOGIA

Este trabalho será desenvolvido durante um estágio remoto com **duração total de 35 horas**, no qual o autor irá elaborar um *software* funcional com os seguintes módulos e passos:[1]

- **Módulo 1: Monitoramento e Alerta de Falhas (Check-up)**

  Desenvolver um programa que realize uma **checagem periódica** (a cada 12 horas, às 06h00 e 18h00) para verificar o *status* operacional da Estação Meteorológica (EM) de Sorocaba (V0498).
  Em caso de falha na coleta de dados, um alerta de não funcionamento será enviado a um endereço de *e-mail* pré-cadastrado. O envio será mantido em repetição até que o funcionamento da estação seja normalizado.

- **Módulo 2: Imputação de Dados por Interpolação Espacial**

  Desenvolver um segundo módulo que identifique as estações meteorológicas próximas e cadastradas na base de dados.
  Capturar os dados das estações vizinhas em funcionamento e aplicar a técnica de **Interpolação Espacial do Inverso da Distância Ponderada (IDW)** para estimar e preencher os dados omissos na série temporal da estação V0498.

- **Módulo 3: Documentação e Proposta de Melhoria (*Yokoten*)**

  Em paralelo à criação das soluções locais, elaborar um **documento técnico** detalhado. Esta documentação deve registrar os procedimentos, identificar as necessidades sistêmicas (não atendidas) e estruturar uma **sugestão formal de projeto mais elaborado** para ser submetido ao INMET, visando aprimorar seus sistemas de coleta e disponibilidade de dados.

RESULTADOS

No **Módulo 1**, verificou-se que o acesso automatizado ao sistema do INMET, para o download programático de dados, não é atualmente suportado. Propõe-se, como sugestão ao órgão federal, a implementação de uma Interface de Programação de Aplicações (API) ou de um serviço web para viabilizar essa coleta de dados.
O **Módulo 2**, focado no processamento de dados, foi concluído com êxito utilizando scripts em Python desenvolvidos nos *notebooks* “Interpolacao.ipynb”, “Comparacao_2_Estacoes.ipynb”, “2_Estacao_MES_a_mes.ipynb” e “Comparacao_Interpolacao.ipynb”, executados na plataforma Google Colaboratory (Colab). O principal resultado foi a **interpolação dos dados ausentes** da Estação de Sorocaba pelo método **IDW (Inverse Distance Weighting)**. Conforme ilustrado na figura 1.

[1] Este documento Relatorio_Tecnico_Cientifico_Estagio.pdf deve acompanhar outro documento, Diario_Bordo_Estacao_Sorocaba.pdf, porque ele traz o passo a passo de todo este trabalho de estágio.

Figura 1 - Comparação da Estação V0498 de Sorocaba antes e depois da interpolação de dados

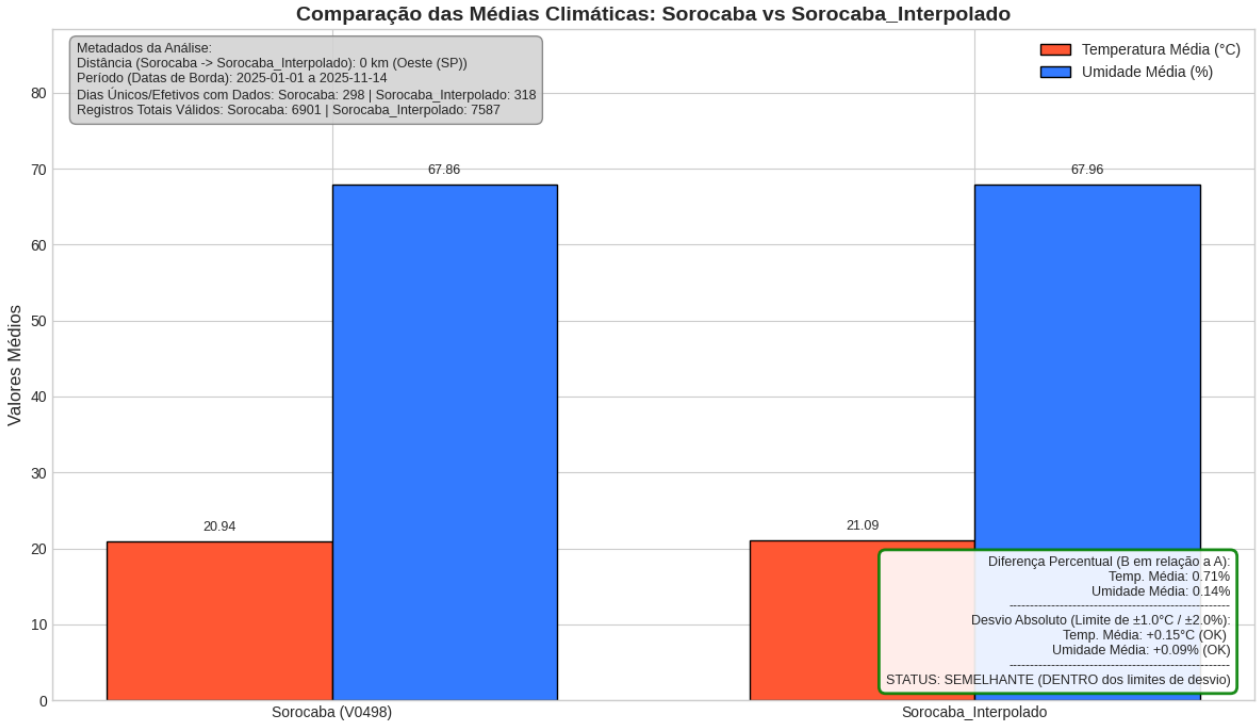

Autor – Resultado do programa Comparacao_2_Estacoes.ipynb

Observou-se uma interrupção na coleta dos dados na série temporal, com a paralisação do registro a partir do dia 15 de outubro às 09:00 UTC.

Para suprir esta lacuna de dados, os valores ausentes na Estação Meteorológica (EM) de Sorocaba foram **estimados** por meio da **interpolação espacial** utilizando o método **IDW (Inverse Distance Weighting)**. Este processo utilizou as séries históricas das **três estações vizinhas (EMs)**: Salto, Cabreúva e Porto Feliz.

Como resultado, a série temporal de Sorocaba foi **completada**. Para fins de rastreabilidade e validação, um **registro de *status*** foi adicionado aos dados preenchidos, distinguindo claramente os valores que foram **interpolados** daqueles que foram obtidos por **leitura direta** da Estação Meteorológica.

.

Figura 2 - Parte dos resultados contendo os dados da EM V0498 completados com os dados Interpolados

	A	B	C	D	E	F	G	H	I	J	K
1	Data	Hora (UTC)	Temp. Ins. (C)	Umi. Ins. (%)	Status_Int.	Salto Temp. Ins. (C)	Salto Umi. Ins. (%)	Cabreuva Temp. Ins. (C)	Cabreuva Umi. Ins. (%)	Porto Feliz Temp. Ins. (C)	Porto Feliz Umi. Ins. (%)
29	15/10/2025	0300	18,4	69,4		18,5	69,7	18,7	74,4	19,7	68,6
30	15/10/2025	0400	18,0	70,5		18,0	68,3	18,2	75,7	19,2	68,1
31	15/10/2025	0500	17,5	70,6		17,5	70,8	18,0	77,5	18,7	68,6
32	15/10/2025	0600	17,3	67,5		17,2	71,9	17,6	79,3	18,3	71,1
33	15/10/2025	0700	17,4	65,5		16,8	74,6	17,4	79,5	17,9	71,8
34	15/10/2025	0800	16,6	69,5		16,1	77,6	17,3	80,4	17,4	73,1
35	15/10/2025	0900	16,79	78,19	Interpolado	15,9	78,9	17,2	80,4	17,1	76,4
36	15/10/2025	1000	17,39	75,66	Interpolado	16,5	78,1	18,3	73,1	17,4	75,7
37	15/10/2025	1100	20,05	66,78	Interpolado	19,5	67,5	21,5	64,2	19,5	67,9
38	15/10/2025	1200	22,63	58,5	Interpolado	22,4	56,9	23,4	60,8	22,3	58,1
39	15/10/2025	1300	24,53	53,31	Interpolado	24,2	51,5	24,9	58,1	24,5	51,5
40	15/10/2025	1400	26,23	49,16	Interpolado	25,9	47,3	26,3	54,9	26,4	46,8
41	15/10/2025	1500	27,85	46,01	Interpolado	27,5	44,6	27,8	51,4	28,1	43,6
42	15/10/2025	1600	29,16	43,82	Interpolado	28,8	41,9	28,8	50,4	29,6	41,0
43	15/10/2025	1700	29,9	42,49	Interpolado	29,3	40,6	29,2	50,3	30,7	38,9
44	15/10/2025	1800	30,33	41,81	Interpolado	28,9	42,0	29,7	49,3	31,6	37,1
45	15/10/2025	1900	30,15	43,59	Interpolado	29,5	41,1	28,6	55,9	31,5	37,6
46	15/10/2025	2000	28,49	48,14	Interpolado	27,8	46,2	26,4	61,3	30,2	41,3
47	15/10/2025	2100	25,96	55,71	Interpolado	24,7	55,1	24,4	67,6	27,7	48,8
48	15/10/2025	2200	22,85	64,73	Interpolado	21,3	65,4	21,9	74,7	24,4	58,2
49	15/10/2025	2300	20,79	71,27	Interpolado	19,5	72,3	20,3	78,5	21,9	66,2
50	16/10/2025	0000	19,62	75,87	Interpolado	18,7	76,0	19,6	81,4	20,2	72,4

Autor – Resultado do programa Interpolacao.ipynb

Para a realização da interpolação, foram definidas como estações de referência três Estações Meteorológicas cujas séries históricas de Temperatura e Umidade demonstram alta coerência e correlação com as da Estação Meteorológica de Sorocaba.

Figura 3 - Comparação das 3 EM em relação à EM Sorocaba

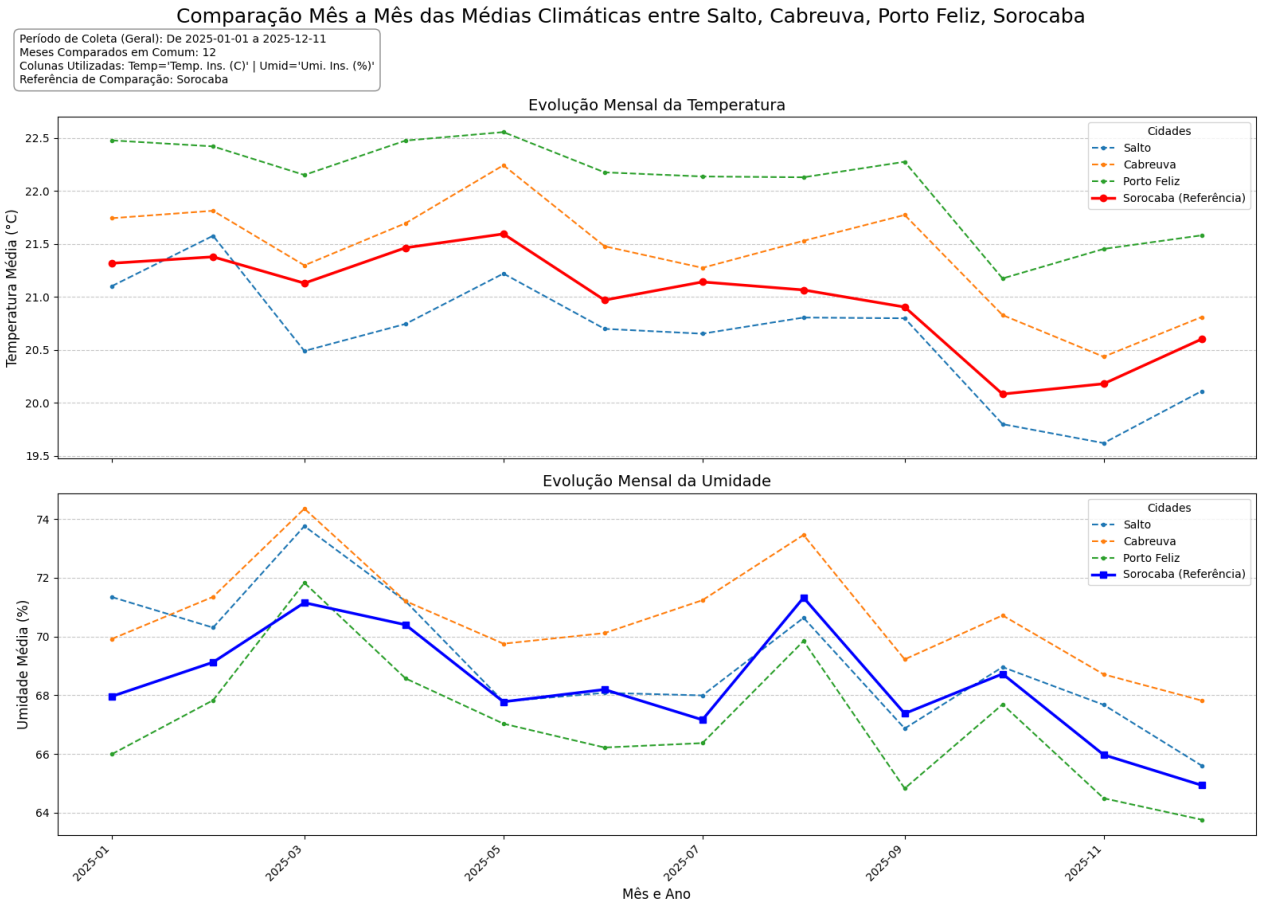

Autor - Comparacao_Interpolacao.ipynb

No **Módulo 3** Com base nos resultados obtidos, são apresentadas as seguintes sugestões à INMET para melhoria da coleta e da qualidade dos dados:

1. **Monitoramento Diário e Alerta de Falhas:** Desenvolver um *software* para **monitoramento diário e automatizado** de todas as 700 EMs cadastradas. O sistema deve emitir um **alerta** de manutenção corretiva urgente aos técnicos de suporte regionais sempre que uma estação deixar de registrar dados.
2. **Criação do Critério "Rosa dos Ventos" para Similaridade:** Formalizar um critério de **similaridade de dados** entre EMs vizinhas, baseado no mapeamento da Rosa dos Ventos. No estudo realizado, foi considerado semelhante uma variação de **1 °C\2%**. Outros parâmetros relevantes e métodos de mensuração de grandes distâncias podem ser incorporados a este critério.
3. **Implementação de Manutenção Preventiva:** Utilizar o histórico de falhas e das inúmeras manutenções corretivas para estabelecer um programa de Manutenção Preventiva. Isso visa reduzir o tempo de paradas e prolongar a vida útil dos equipamentos.

Figura 4 - Rosa dos Ventos na EM de Sorocaba (V0498)

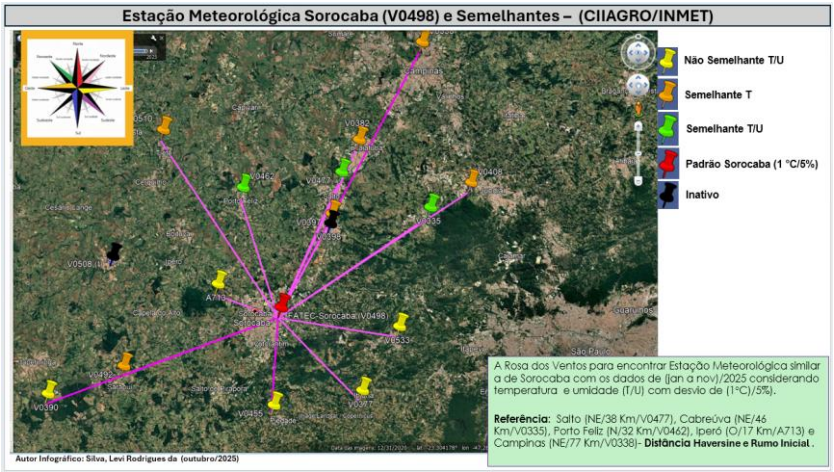

Autor – Usando Google Earth Pro e dados do INMET das EM

A figura 4 ilustra a **Rosa dos Ventos** no entorno da Estação Meteorológica (EM) de Sorocaba, fornecendo um panorama da coerência espacial dos dados. Neste estudo, foram identificadas e utilizadas como referência as estações vizinhas que demonstraram similaridade de dados de Temperatura e Umidade (indicando estarem livres de interferências significativas de microclimas), sendo ideais para o **preenchimento de lacunas** por meio de interpolação.
Nota: Os desafios operacionais e técnicos adicionais, identificados durante a coleta e o processamento inicial dos dados, estão detalhados no relatório **"Diario_Bordo_Estacao_Sorocaba.pdf"**, que acompanha este documento como anexo. Este diário foi elaborado de forma progressiva, registrando a experiência prática da execução do estudo.

Foi checado que em todas as estações meteorológicas há perdas.
Então foi elaborado um programa de Inteligência Artificial para prever as perdas dos próximos 6 meses.
LSTM: As redes **RNN** vieram para cobrir as tarefas de séries temporais e dados sequenciais, que é o caso da nossa EM .
As redes LSTM normalmente têm mais parâmetros devido às portas adicionais e ao estado da célula.

Figura 5 - Uma célula de LSTM comparada com seu antecessor e com outra opção moderna GRU.

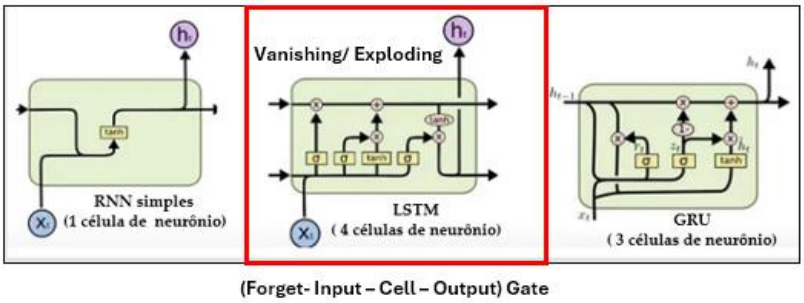

Autor

o Machine Learn-Supervisionado (Regressão)-Deep Learn-LSTM.
Os parâmetros e hiperparâmetros principais usados:

- Erros ou Costs
- Gradiente descendente
- *Weights* e *Bias*
- *Epoch*

- Taxa de aprendizado
- *Batch*
- Número de neurônios
- *Early Stop*
- *Look-Back*
- Normalização *MinMaxScaler (Fica entre 0 e 1)*
- Divisão de dados 60% treino, 20% validação e 20% teste

Enquanto os **parâmetros** do modelo são ajustados internamente com dados durante o treinamento, os **hiperparâmetros** são definidos externamente pelo engenheiro IA e devem ser otimizados para obter o melhor desempenho do modelo.
Usamos dados de Iperó que é a EM mais próxima e de Sorocaba, dando um alcance de 2018 a 2025. (2018 a 2021- Iperó).

Figura 6 - Divisão do DataSet para a IA ser treinado e criar um modelo

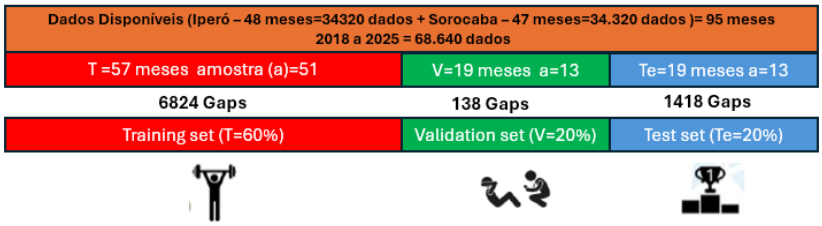

Autor

Nos hiperparâmetros alterados, aumentamos e diminuímos o número de neurônios, mesmo procedimento para *Epoch* e look-back. O melhor modelo ofereceu:

Figura 7 - Modelo Keras do LSTM

Layer (type)	Output Shape	Param #
lstm_22 (LSTM)	(None, 100)	40,800
dense_19 (Dense)	(None, 1)	101

```
Total params: 40,901 (159.77 KB)
Trainable params: 40,901 (159.77 KB)
Non-trainable params: 0 (0.00 B)
```

Autor

Figura 8 - Modelo Deep Learn LSTM

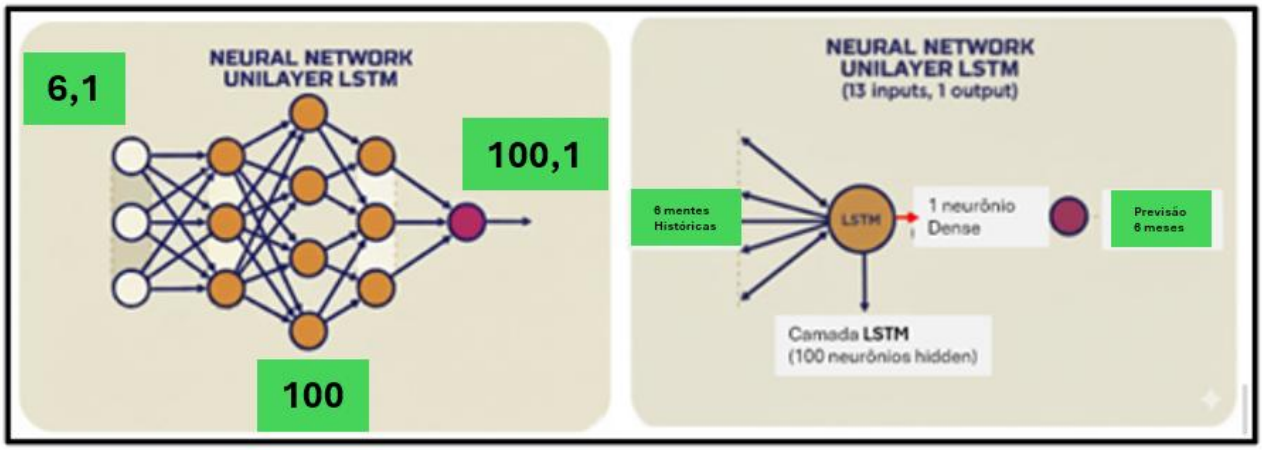

Autor

Este foi o resultado do modelo no programa **LSTM_GAP_SOR.ipynb**.

Figura 9 - Treinamento e comparação de dados reais com previsão

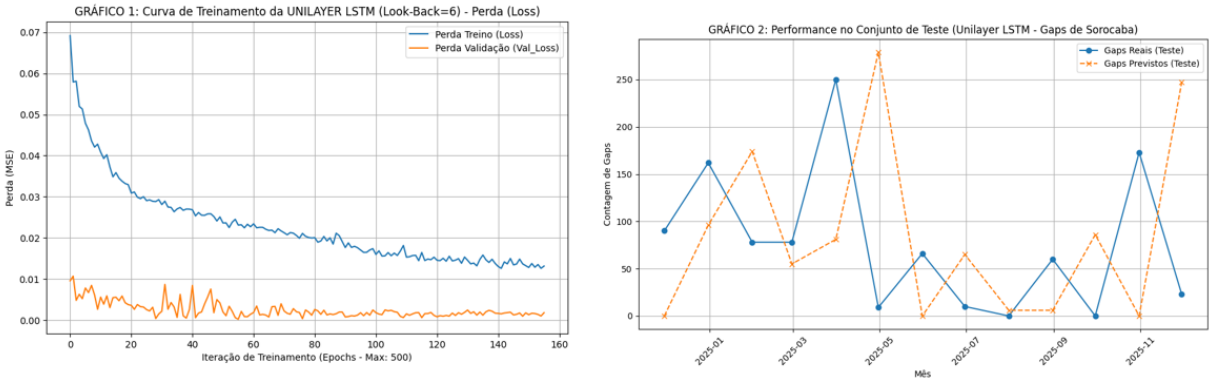

Autor

Figura 10 - Previsão de perdas (GAP) para os próximos 6 meses EM de Sorocaba

```
================================================================================
### GRÁFICO 3: PROJEÇÃO DE 6 MESES NO FUTURO (PLOTLY - Interativo) ###

PROJEÇÃO UNILAYER LSTM (Look-Back=6) PARA GAPS DE Sorocaba (Próximos 6 Meses):
Total de Gaps Previstos (6 Meses): **29**
```

	Mês de Projeção	Gaps Previstos
0	2025-12-30	0
1	2026-01-30	0
2	2026-02-28	0
3	2026-03-30	0
4	2026-04-30	0
5	2026-05-30	29

Autor

CONCLUSÃO

Baseadas nos Módulos 1, 2 e 3 e nas Figuras apresentadas, destacam tanto o sucesso metodológico da interpolação quanto as contribuições práticas para a melhoria da gestão de dados do INMET.

A principal conclusão metodológica do estudo é a eficácia e a robustez do método **IDW (Inverse Distance Weighting)** na gestão da qualidade de dados, especificamente no preenchimento de lacunas de séries temporais horárias.

Validação da Metodologia: O Módulo 2 demonstrou o êxito na interpolação dos dados ausentes da Estação Meteorológica (EM) de Sorocaba, resultando em uma série temporal completa e consistente (conforme ilustrado na Figura 1).

Coerência Espacial: A escolha das três estações vizinhas (Salto, Cabreúva e Porto Feliz) foi validada pela **alta coerência e correlação** de suas séries históricas de Temperatura e Umidade com a estação-alvo (Figura 3). O mapeamento da **Rosa dos Ventos** (Figura 4) complementa essa validação, confirmando que os dados de entrada para o IDW estão livres de interferências significativas de microclimas.

Rastreabilidade Assegurada: Foi implementado um registro de *status* (Figura 2) que distingue inequivocamente os valores **interpolados** dos valores obtidos por **leitura direta** da Estação Meteorológica. Esta prática eleva o nível de rastreabilidade e validação do conjunto de dados, um requisito fundamental para aplicações de modelagem e pesquisa que exigem o conhecimento da origem exata de cada ponto de dados.

O **Módulo 1** não apenas identificou a limitação tecnológica, mas também resultou em uma recomendação de alto impacto: **Barreira à Automação** e a **Interface de Programação de Aplicações (API)** ou serviço WEB, indicando o caminho para a modernização da infraestrutura do órgão federal e o fomento à ciência de dados aberta no setor meteorológico.

Estratégia de Manutenção: A análise do histórico de falhas deve subsidiar a migração de um modelo reativo (Manutenção Corretiva) para um Programa de Manutenção Preventiva. Isso garantirá a longevidade dos equipamentos e a confiabilidade de longo prazo da rede de coleta.

A IA para previr as perdas ou gap nos próximos meses na EM de Sorocaba, mostra uma tendência das outras EM de ter perdas. O que justifica novos projetos robustos e a manutenção preventiva sendo aplicados.

Anexo 1

Fundamentos da Geodésia Esférica: Distância de Haversine. Rumo Inicial e Interpolação IDW

Fundamentos da Geodésia Esférica: Distância de Haversine. Rumo Inicial

O cálculo preciso de distâncias e direções na superfície terrestre exige a aplicação da **geometria esférica**, em detrimento da geometria plana (distância euclidiana), especialmente para distâncias superiores a 10 e 20 km. Para este fim, são empregadas as fórmulas de Haversine e do Rumo Inicial, descritas a seguir.

$$a = \sin^2\left(\frac{\Delta\phi}{2}\right) + \cos(\phi_1)\cdot\cos(\phi_2)\cdot\sin^2\left(\frac{\Delta\lambda}{2}\right)$$

$$d = 2\cdot R\cdot \arctan 2\left(\sqrt{a}, \sqrt{1-a}\right)$$

Onde:

Φ_1 e Φ_2 Latitudes dos pontos A e B em radianos.
λ_1 e λ_2 Longitude dos pontos A e B em radianos.
$\Delta\Phi$ Diferença de Latitude (Φ_2 - Φ_1)
$\Delta\lambda$ Diferença de Longitude (λ_2 - λ_1)
R raio da terra Aproximadamente 6371 Km
arctan 2 (y,x) Função arco tangente de 2 argumentos
d Distância Geodésica de Haversine entre os pontos.

Termo a (Haversine Central): Calcula o quadrado da metade do comprimento da corda que conecta os dois pontos na esfera. É a parte central da fórmula que traduz as diferenças angulares em uma medida de corda.
Termo d (Distância Final): A expressão d/R representa o ângulo central (em radianos) entre os dois pontos.
Multiplicando o ângulo central pela função arctan2 e depois por 2R, obtemos o comprimento do arco na superfície, que é a distância final.

O Rumo Inicial (também chamado de *Azimute* ou *Bearing*) é o **ângulo de direção** que deve tomar para ir do Ponto A ao Ponto B. Ele é medido em graus, no sentido horário, a partir do Norte verdadeiro (0°).

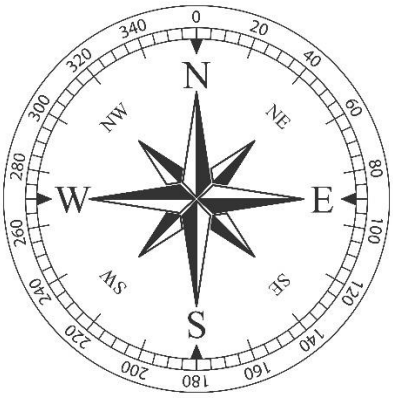

Figura 11 - Bússola que indica a direção, com ao Rosa dos Ventos.

A fórmula do Rumo Inicial beta (β) também usa coordenadas em radianos e é baseada na função Arco Tangente de 2 argumentos (arctan 2):

$$\beta = \arctan 2\left(\sin(\Delta\lambda)\cdot\cos(\phi_2),\quad \cos(\phi_1)\cdot\sin(\phi_2) - \sin(\phi_1)\cdot\cos(\phi_2)\cdot\cos(\Delta\lambda)\right)$$

β Rumo inicial em radianos.

Interpolação IDW

A Interpolação **IDW** (do inglês, Inverse Distance Weighted ou Ponderação pelo Inverso da Distância) é um método de análise espacial muito utilizado, especialmente em Sistemas de Informação Geográfica (SIG).
O principal conceito é: a influência de um ponto de amostragem na estimativa de um valor desconhecido diminui à medida que a distância entre eles aumenta.

O IDW é um interpolador determinístico que estima o valor em um local não amostrado com base nos valores observados nos pontos circundantes, seguindo as seguintes premissas:

- **Ponderação pela Distância:** Os pontos mais próximos têm um peso maior e, portanto, influenciam mais na previsão.
- **Inverso da Distância:** O peso é inversamente proporcional à distância entre o ponto conhecido e o ponto a ser estimado, elevado a um determinado expoente (geralmente p).

A Fórmula (de forma simplificada)
A estimativa do valor interpolado (p) em um novo ponto é dada por uma média ponderada dos valores dos pontos de amostragem conhecidos (z):

$$Z_p = \frac{\sum_{i=1}^{n}\left(\frac{1}{d_i^p}\cdot z_i\right)}{\sum_{i=1}^{n}\left(\frac{1}{d_i^p}\right)}$$

Onde:

- Z_p: é o valor estimado no ponto P.
- Z_i: é o valor do atributo no i-ésimo ponto de amostragem.
- d^i: é a distância entre o i-ésimo ponto de amostragem e o ponto P.
- p: é o **expoente de ponderação**.

O Expoente de Ponderação (p)

O parâmetro **p** é crucial e geralmente é ajustado pelo usuário:

- **Se p é maior**, a influência dos pontos mais distantes **diminui mais rapidamente**. A superfície interpolada resultante será mais "pontuda" ao redor dos pontos de amostragem.
- **Se p é menor** (por exemplo, 1), a influência dos pontos é mais distribuída, resultando em uma superfície mais suave.
- O valor padrão frequentemente utilizado é p=2.

Existem outro modelos de interpolação e cada um com suas características.